生成臨床 UI の更新における層間整合性の評価

ANONYMOUS AUTHOR(S)

データを使う UI では、実行できる状態でも、更新によって要求と異なる情報を表示することがある。本研究は 8 種類の不整合を含む 763 組の更新を用い、参照情報に依存する検査を調べる。局所検査は構築条件によって全不整合を受理し、二つの層間検査はすべて拒否したが、参照情報と検査関数を共有する。追加の SQL 評価では、結果を保つ別解 648 件も拒否し、SQL 一致を外した判定は結果変更 476 件のうち 329 件を受理した。別の探索的な予備評価では、Gemini で制約された合成 UI 更新を 20 件生成した。2 件で保持すべき期間条件が消え、要求に応じた結果の検査は両方を拒否して、残る適合 18 件を受理した。参照 SQL との一致は適合 3 件も拒否した。ただし、事後に追加した簡単な期間条件の検査でも同じ判定となり、データ状態を増やしても差は出なかった。変更・保持条件を明示する課題は示されたが、グラフ形式の優位性、一般的な意味の検証、臨床的な効果は示していない。

CCS Concepts: • **Human-centered computing → Human computer interaction (HCI)**; *Interactive systems and tools*.

Additional Key Words and Phrases: 生成ユーザーインターフェース, データ駆動型 UI, 電子カルテ, 整合性検査, 増分更新, 追跡可能性

ACM Reference Format:

Anonymous Author(s). 2027. 生成臨床 UI の更新における層間整合性の評価. In *Proceedings of 2027 CHI Conference on Human Factors in Computing Systems (CHI '27)*. ACM, New York, NY, USA, 15 pages. https://doi.org/10.1145/nnnnnnn.nnnnnnn

1 はじめに

診療記録には、一つのタスクで確認する範囲を超える情報が含まれる場合がある。情報を選び、画面へ配置する際には、患者、項目、期間、情報源、表示方法を決める必要がある。表示を絞る過程で、要求と取得内容のずれが見えにくくなる可能性もある。本稿は、更新時にそのずれを検査する技術的な方法を扱う。人の情報処理能力や確認負担の変化は測定しない。

例えば、術前評価では直近の情報をまとめ、術後フォローでは項目の推移と最新値を組み合わせる画面が考えられる。これらは着想を説明する設計例であり、確認済みの診療要件や評価タスクではない。要求に応じて表示情報を変えるとき、要求から表示までの対応を調べる動機として用いる。

この目的に対し、従来の技術検査では確かめられない部分がある。SQL の構文と実行、結果形式、UI コード、画面描画は、それぞれ個別に確認できる。しかし、各成果物が正常でも、SQL だけが別の患者を参照する、期間条件だけが外れる、更新前の結果が残る、表示部品が別のデータを参照するといった誤りは起こり得る。SQL の正答率が上がっても、その後の実行、接続、表示まで同じ要求が保たれなければ、医療者へ返る情報は正しくならない。

本稿では、診療場面から定めた情報要求と、最終的に表示される情報の対応が途中で崩れた状態を**層間不整合**と呼ぶ。生成臨床 UI の品質を、情報要求から表示までの一連の流れとして捉える。ここでいう正しさは、医学的判断全体の正しさではない。あらかじめ定めた患者、項目、期間、集約、情報源、表示方法、接続、版が、更新後も一致していることを指す。

生成・編集可能な UI の研究では、中間表現を通じて要求と UI を結ぶ。Jelly は変化するタスクのデータモデルを保持し [2]、Bridging Gulfs は設計意図を意味表現として示す [9]。SimStep はタスクレベルの抽象表現を使い、段階ごとの確認・訂正に加えて、変換間の忠実性も評価している [6]。本稿は、要求とデータの対応に 8 種類の不整合を注入し、同じ候補へ 4 種類の検査を適用する比較に焦点を絞る。

本研究は、生成臨床 UI の更新を対象に、既知の参照情報を使う回帰テストの基盤を作った。EHRSQL-2024 の注釈付き質問と正解 SQL[7] を、MIMIC-IV Clinical Database Demo v2.2[5] で実行する。最小限のデータ成果物と表示部品を構築し、8 種類の不整合を注入する。この正式評価では UI 生成モデルや画面の描画を実行しない。別の制約された生成課題は 5.8 節で扱う。候補の妥当性を判定する処理であるオラクルと、二つの層間検査は、既知の目標ケースから得た同じ参照項目と期待値を使う。本稿では、この組を契約と呼ぶ。信頼できる参照情報がある条件で、定義した検査が注入した不整合を捉えるかを調べる。

本研究では次の問いに答える。

RQ1 定義した 8 種類のうち、局所検査を通過する不整合を構築できるのはどれか。

RQ2 局所検査、成果物内検査、質問から表示までをまとめて照合する検査では、不整合の見逃し、妥当な更新の受理、不整合の種類の報告がどう異なるか。

RQ3 拒否した不整合の種類が報告されたとき、保存済みの妥当成果物を使う一回の復元でどの範囲を戻せるか。

評価方法を固定した後、テスト分割を一度だけ実行し、134 種類の質問テンプレートから 763 組の更新ペアを作った。4 条件での検査は 6,104 回となった。局所検査の通過を候補の採用条件としているため、局所検査は不整合をすべて受理した。成果物内検査は 367 件を受理し、二つの層間検査は不整合をすべて拒否して、基準を満たす候補をすべて受理した。層間検査は期待値と主要な検査関数を共有する。両者の一致はこの実装の整合確認であり、保存形式の効果を独立に検証した結果ではない。

探索的な追加評価では、同じデータベースで列と型付き結果の多重集合を保つ SQL の別解 648 件を、二つの層間検査がすべて拒否した。SQL の一致検査を外した判定では別解を受理したが、等号の反転で結果が変わる 476 件のうち 329 件も受理した。参照情報から作った候補を受理することと、妥当な別解を受け入れることは区別する必要がある。

本稿は、対象範囲を限定した評価基盤として次を示す。

- 要求、SQL、結果、表示の対応を調べるための 8 種類の不整合と、候補を採用する条件を明示した。
- 基準を満たす候補と不整合候補を組にし、4 条件で検出、種類の報告、参照情報を使う復元を記録する再現可能な手順を示した。
- 実装した検査ごとに捉える不整合と見逃す不整合を整理し、必要な参照情報を明示した。

本評価は技術評価であり、診療シナリオ自体の医学的妥当性、臨床上の安全性、診療判断の正確さ、使いやすさ、認知負荷、臨床転帰を評価していない。技術的な対応と利用者への効果を分けて扱う。

2 関連研究

2.1 生成・編集可能な UI

生成 UI の研究は、自然言語や例示から画面を生成する段階から、生成物を利用者が理解し、編集し、再利用できる段階へ広がっている。DirectGPT は、会話に加えて生成物そのものを直接操作し、参照解決を支えることで、生成 AI との反復的な作業を扱った [8]。DynaVis は、可視化の生成と編集を対話的に行い、生成された UI 上の操作を自然言語対話と組み合わせた [11]。これらの研究は、生成物を継続的に変更できる対話対象として扱う。

更新を支えるため、中間表現を導入する研究もある。Jelly は、タスク駆動データモデルを生成 UI の背後に置き、タスクの変化をデータと画面に反映する [2]。Bridging Gulfs は、意味表現を通じて利用者の意図、生成モデルの解釈、出力 UI の隔たりを小さくする [9]。SimStep は、概念、シナリオ、学習目標、UI のグラフを分け、人が各段階の仮定を編集できるようにする [6]。これらの設計では、中間表現が検査や修正の接点になる。

本研究は、既知の参照情報を持つ更新に不整合を入れ、定義した検査がどこまで捉えるかを調べる。初回生成の品質や編集体験は比較しない。グラフ検査と表形式検査は、共通の検査処理に対する二つの参照経路であり、保存基盤の効果を切り分ける比較ではない。

2.2 人と生成システムの協働における検査と修正

AI システムの利用者は、出力を単純に採用または拒否するだけではない。Ignore, Trust, or Negotiate は、医療者が AI の提案を無視、信頼、交渉しながら取り込む過程を示し、不確実さや根拠を扱う相互作用の必要性を論じた [10]。生成 UI でも、壊れた関係、修正箇所、修正の影響範囲を示す診断が、利用者の判断を支えられる可能性がある。

拒否できることと、修正に役立つ診断を返せることは一致しない。本研究は、拒否、注入した種類の報告、保存済みの妥当成果物を使う復元を記録する。後二つの指標は、復元手順によって結び付いている。診断を見た人が問題箇所を見つけ、修正できるかは測っていない。

2.3 自然言語質問からデータ取得と表示まで

Text-to-SQL 研究は、自然言語の質問から実行できる SQL を生成し、質問へ正しく答えられるかを評価してきた。EHRSQL-2024 は電子カルテを対象に、回答可能な質問と回答不能な質問を含む共有タスクを提供する [7]。この評価では、質問に対応する SQL を生成できるか、答えられない質問で棄権できるかが中心になる。

本研究は SQL 生成の性能を比較しない。正解 SQL を基準として使い、その後に生じる層間不整合を扱う。正しい SQL が一度得られても、UI の更新時には、質問、SQL、結果、表示のいずれかだけが別の版に更新される可能性がある。また、変更後の SQL を実行できても、対象患者や期間が要求とずれる場合がある。したがって、質問と SQL の対応に加えて、SQL と実行結果、結果と表示方法、データ取得と表示部品の接続、更新版の一致を検査する必要がある。

2.4 モデル変換と整合性

構造化データとビューの更新は、双方向変換の研究で扱われてきた。Lens は、元データとビューの往復変換が満たす性質を定式化する [3]。完全な正解出力を列挙しにくいモデル変換には、メタモルフィックテストを使う研究もある [4]。テストで正しい振る舞いを判定する方法はオラクル問題として研究され、仕様や既存の実行から基準を得る手法が整理されている [1]。本実装は限定した参照判定を使い、既知の目標から得た問い合わせ、結果、参照先の特定項目との一致を求める。Lens の法則や一般的な意味の同値性を実装したものではない。

本稿は、データを使う UI の更新で、要求、問い合わせ、結果、表示のどこを故障として変え、どの参照項目で検査するかを具体化する。故障を注入して検査範囲を確かめる考え方自体を、新しい方法として主張しない。

3 臨床的な問題設定と評価範囲

3.1 シナリオごとに変わる情報要求

本研究の着想につながった設計過程では、麻酔科術前外来と甲状腺術後フォローを診療シナリオとして整理した。麻酔科術前外来では、手術日を基準に患者背景、術式、生活歴、アレルギー歴、既往歴、治療歴、直近の検査、麻酔歴を集約し、最後に麻酔リスクをまとめる。情報の中心は、一回の術前評価に必要な最新状態である。甲状腺術後フォローでは、診察日を基準に甲状腺機能、超音波所見、チラーヂン補充量を確認する。この設計例では甲状腺機能と補充量に直近 12 か月の推移を用い、最新値だけを示す部分と経時変化を示す部分を使い分ける。

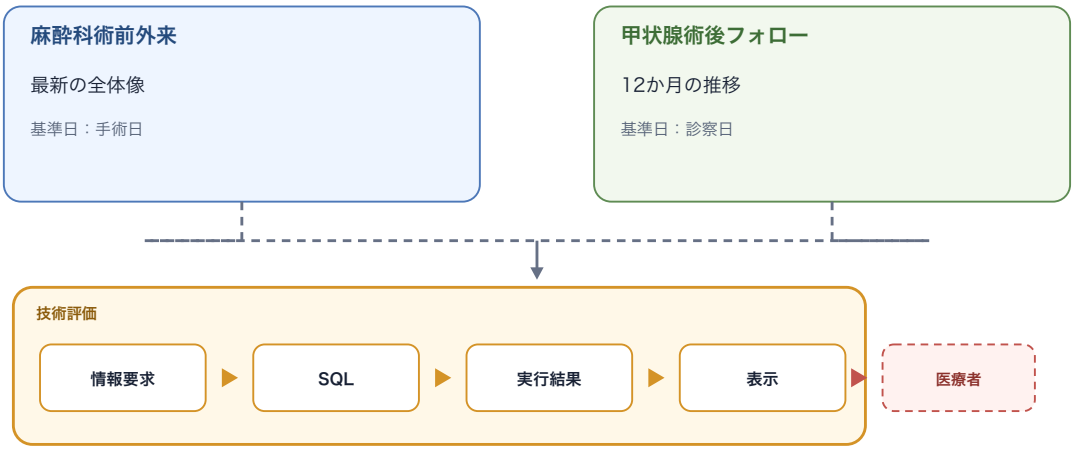


Fig. 1. 診療シナリオによって必要な情報と表示が変わる例。術前外来（左）は手術日を基準に、患者背景、手術情報、直近検査の最新の状態をまとめる。甲状腺術後フォロー（右）は診察日を基準に、甲状腺機能と補充量の 12 か月の推移に超音波所見を組み合わせる。本稿は情報要求から表示までを技術評価し、医学的妥当性と医療者への効果は別に評価する。二つのシナリオは正式評価ケースではない。

図 1 は、この違いと本稿の評価範囲を示す。二つのシナリオは、同じ電子カルテでも、抽出すべき情報と表示方法が診療場面によって変わることを説明するための設計例である。正式評価の正解データには使っておらず、現在のタスクモデルも専門家の確認を終えた臨床基準ではない。

3.2 技術的な対応と利用者への効果

生成臨床 UI が医療者に価値をもたらすまでには、少なくとも三つの条件がある。まず、専門家が診療シナリオに必要な質問、情報、完了条件を定める。次に、システムがその情報要求を正しいデータ取得と表示に変換する。最後に、医療者が表示を使って必要な情報を確認し、診療タスクを行う。本稿が測るのは二番目に関係する参照項目の検査であり、正しい目標を既知とする。情報要求から表示への変換全体を評価するものではない。

層間整合性が高ければ確認負担や見落としが減るとは、本結果だけでは言えない。本稿では、参照項目の技術的な検査を利用者体験と分けて扱う。後の利用者評価では、情報の正しさを操作時間や好みと合わせて調べ、速くても誤った応答を診療タスクの成功と数えないようにする必要がある。

3.3 何を情報の誤りと呼ぶか

情報の正しさには複数の段階がある。本稿では、元データの記録内容が事実か、診療シナリオのタスク定義が医学的に適切か、表示を見た医療者の判断が正しいかを評価しない。本稿が扱う**情報の誤り**は、定められた情報要求に対して、画面へ届いた情報が患者、項目、期間、集約、情報源、表示方法、接続、版のいずれかで一致しない状態である。層間不整合は、この誤りがどの成果物の間で起きたかを示す。

この定義は、形式が不正な SQL と、形式が正しくても要求と異なる情報を取得する SQL を区別する。局所検査は、許可された SQL の形式と成果物の互換性を調べる。要求との不一致を調べるには、信頼できる期待値も必要になる。本評価の層間検査は、目標ケースからその期待値を得る。

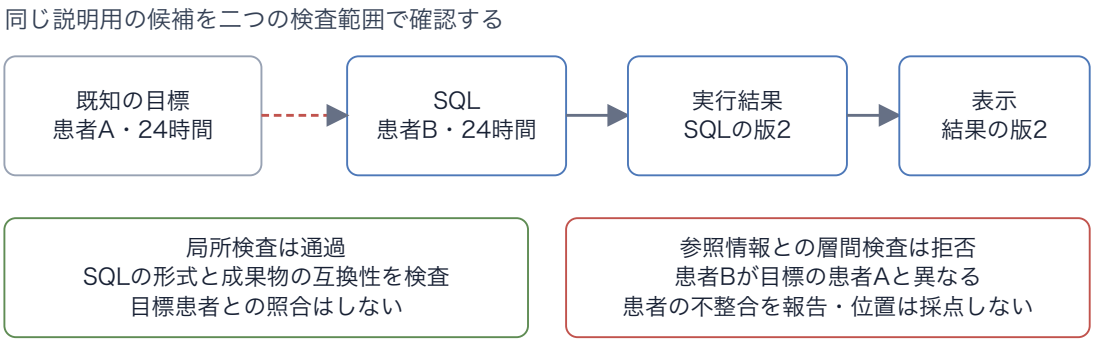


Fig. 2. 架空の患者ラベルを使った不整合の説明例。局所検査は SQL の形式と成果物の互換性を調べるが、要求された患者とは比べない。層間検査は既知の目標契約と照合する。期間は 24 時間のままで、SQL の患者 B が参照情報の患者 A と異なる。診断は患者の不整合を報告できるが、本評価は正確なノードや辺の位置を採点しない。

4 層間整合性の定義

4.1 対象とする情報の流れと検知の仕組み

本研究は、情報要求、SQL、実行結果、表示部品の 4 層を扱う。情報要求は、対象患者、対象項目、期間、集約、情報源、期待する表示方法を含む。SQL は要求をデータベース操作に変換する。実行結果は SQL、入力、実行時点に対応する版を持つ。表示部品は、結果を参照し、その形状に適した方法で提示する。

図 2 は、患者だけがずれた例を示す。実装では、任意の文章から医学的に正しい意図を読み取るのではなく、目標ケースの注釈と正解 SQL から期待値を作る。問い合わせ、結果、参照、表示の特定項目を比べ、問題コードと種類のラベルを返す。図は概念上の流れを示す。実際の検査項目と、正解判定・復元に渡す参照情報は後の評価方法で明記する。

故障モデルを概念的に整理するため、更新候補 c で保つ対応を述語の論理積で表す。実装は参照情報の特定項目を照合する。この式は、一般的な意味の同値性を判定する手順ではない。

$$I(c) = P(c) \wedge D(c) \wedge T(c) \wedge A(c) \wedge S(c) \wedge V(c) \wedge L(c) \wedge R(c) \tag{1}$$

P は患者、D は項目、T は期間、A は集約、S は情報源、V は表示方法、L はデータと表示の接続、R は SQL と実行結果の版の一致を表す。この式は故障モデルの整理であり、正解判定の実装をそのまま表したものではない。各不整合候補に適用する変異規則は一つだが、複数の検査項目が不一致になる場合がある。特定の参照項目への一致は、一般的な意味の同値性より狭い基準である。

4.2 8 種類の不整合

表 1 に不整合の定義を示す。対象患者の不整合では、要求側の患者を保ったまま SQL の患者条件を別の患者を指す値に変える。対象項目では、要求と異なる列または集約対象を取得する。期間では、要求の時点や期間に対応する条件を変える。集約方法では、件数、最大、最小、平均などを別の演算へ置き換える。

情報源の不整合では、SQL と結果を保ったまま、記録された情報源の表一覧を変える。別の表を問い合わせる実験ではない。表示方法では、SQL とデータを保ち、数値カードをデータフレームへ、またはデータフレームを別の表部品へ変える。この不整合ラベルは、あらかじめ定めた表示規則への違反を指す。別の表示が利用者を誤らせることや医学的に不適切なことを示すラベルではない。接続では、列と表示種類に互換性がある更新前の

Table 1. 評価で生成する 8 種類の層間不整合

種類	変更するもの	構築時に保つ性質
対象患者	SQL の患者条件	構文、読み取り専用、実行
対象項目	取得列または集約対象	構文、実行、結果型
期間	時点・期間条件	構文、実行
集約方法	件数、最大、最小、平均など	構文、実行、結果型
情報源	記録された情報源の表一覧	SQL は変更しない
表示方法	結果を示す部品の種類	参照と形状の検査
接続	部品が参照するデータ取得	個別ノードの型
古い結果	SQL 更新後の結果版	既存の結果構造

データノードへ表示部品をつなぐ。古い結果では、結果のチェックサムが異なる更新前の結果を、更新後の SQL へ結び付ける。

これらは臨床現場で観測したエラー頻度の分類ではない。どの関係を検査する必要があるかを測定可能にするための故障モデルである。各候補には一種類だけを注入するため、結果は複合故障への性能を示さない。

5 評価基盤

5.1 基準ケースの構築

入力は EHRSQL-2024 の回答可能な質問と正解 SQL である。回答不能ケースは正解 SQL から基準 UI を構築できないため、主評価から除外し、件数を記録する。正解 SQL は MIMIC-IV Demo v2.2 の SQLite データベースに対して読み取り専用で実行する。書き込みを含む文、複数文、許可しない構文は実行前に拒否し、SQL ごとの実行上限を 5 秒とした。

実行結果が単一値なら数値カード、複数行または複数列ならデータフレーム表示を基準とする。空結果は除外せず、列構造を持つ結果として扱う。基準ケースは、質問テンプレートに対応する患者、項目、期間、集約の注釈、SQL の解析結果、結果形状、データノード、表示部品、各成果物の版を保持する。

質問テンプレートの文字列ごとにケースをまとめ、同じ群の中で更新前後の組を作る。テンプレートと不整合の種類ごとに、seed 付きハッシュで適用候補を並べ、構築条件を最初に通る組だけを採用する。各テンプレート・種類の組は最大 1 件となる。同じテンプレートは複数の種類に現れ、元のケースが再利用される場合もある。これは構築した遷移であり、利用者の実際の編集履歴ではない。

採用には、妥当候補が正解判定を通ること、不整合候補が正解判定を通らないこと、不整合候補が局所検査を通ることを求める。最後の条件により、局所検査で見つからない故障に評価対象を絞っている。したがって、局所検査の流出率 100%は構築条件によって決まり、自然な生成候補でのエラー頻度や局所検査の精度を推定した値ではない。

5.2 参照情報に基づく正解判定

正解判定は変異生成と検査条件の振り分けとは別の処理で実装したが、同じ目標ケースの契約を使う。照合するのは、質問のチェックサム、正規化した正解 SQL のチェックサム、情報源の表一覧、結果に記録した SQL のチェックサム、結果値と列のチェックサム、表示部品の ID、参照先、列、表示種類である。これは参照情報の特定項目との一致判定であり、臨床的な意図や SQL の意味的同値性を独立に判定する処理ではない。

JSON 全体の完全一致は求めないが、選択した ID、列順、SQL のチェックサムなどは一致が必要になる。同じ意味を持つ別の SQL や表示も、この基準では不一致になり得る。妥当候補は参照情報から作るため、その受理率

Table 2. 比較する 4 種類の検査条件

条件	個別成果物	層間関係	参照方法
局所検査	基本検査	参照の存在・形状	各成果物
成果物内検査	詳細検査	一部	各成果物
グラフ検査	下位条件と共通	目標との一致	参照をたどる
表形式検査	下位条件と共通	同じ目標との一致	平坦な項目

は多様な正解を受け入れられる割合を示さない。処理を分けても、参照情報の誤りが生成器、正解判定、層間検査に共通して影響する可能性は残る。

5.3 4 種類の検査条件

同じ候補を表 2 の 4 条件に入力する。局所検査は、SQL の構文と読み取り専用の形式、ノード参照の存在、空でない列構造、表示列が結果に含まれること、数値カードの形状条件を調べる。SQL の実行は候補構築時に行い、時間を測る検査呼び出しには含めない。ブラウザの描画は検査しない。成果物内検査は、記録された情報源と SQL の参照表、結果に記録された SQL のチェックサムと現在の SQL、表示部品の種類と結果形状から割り当てた種類を追加で比べる。この名称には隣接する成果物の照合も含む。要求の注釈や表示先を、目標の参照情報全体と比べる処理は含まない。

グラフ検査は、質問、目標データ成果物、表示部品の参照をたどり、目標の契約と比べる。表形式検査は、平坦に並べた項目を同じ期待値と比べる。その後の SQL の意味要素、目標データ、表示部品の検査関数は両条件で共有する。SQL の検査は、注釈された値や正規化した断片に加え、正解 SQL のチェックサムとの一致も求める。自由な自然言語から正しさを判断する処理ではない。両条件は同じ検査処理へ異なる経路でアクセスする実装であり、独立した保存基盤の比較ではない。一致した結果から保存形式の因果的な効果は判断できない。

5.4 不整合の種類の報告と参照情報を使う復元

診断には問題コードと層のラベルを含め、種類を報告する場合もある。種類の報告に成功したと数えるのは、報告された種類の集合に、注入した種類が含まれる場合である。診断が一つだけであることは求めず、余分な種類を返しても、この指標では減点しない。正確なノードや辺の位置も採点しない。このため、指標は不整合の種類を報告できた割合として解釈する。

復元処理には、注入した種類と保存済みの妥当候補を渡す。報告された種類に注入した種類が含まれれば、SQL、情報源、古い結果の変異では目標データ成果物全体を、表示方法と接続の変異では表示部品全体を妥当候補からコピーする。種類が含まれなければ変更しない。復元後は、同じ検査条件と参照情報に基づく正解判定を両方通過した場合だけ成功とする。

この手順は、正解を含む参照情報がある場合の復元を測る。診断だけから原因の種類を推定したり、最小の修正を生成したりする能力は測らない。復元を試みる条件にも、既知の不整合ラベルと検査による拒否を使う。そのため、妥当候補を誤って拒否した場合に、不必要な変更を加える危険は評価していない。

5.5 評価手順

図 3 に評価手順を示す。開発用データでは、異なる質問テンプレートを優先した 50 件で、SQL を実行して基準ケースに変換できることを確かめた。調整確認用データでは、不整合ごとの候補数、質問テンプレート数、ラベ

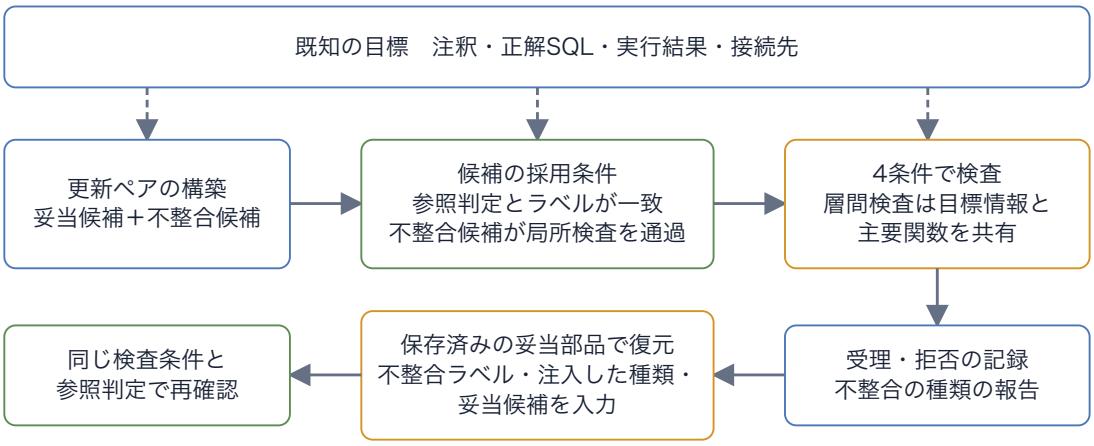


Fig. 3. 評価手順と参照情報。候補のラベルが参照判定と一致し、不整合候補が局所検査を通る場合だけ採用する。正解判定と二つの層間検査は同じ目標契約を使い、層間検査は主要関数も共有する。復元には既知の不整合ラベル、注入した種類、保存済みの妥当候補を渡し、同じ検査条件と正解判定で再確認する。

ルの一致、機微情報が保存されないことを確かめた。列順の不整合を作れなかったため、テスト分割を見る前に表示方法の不整合に置き換えた。他の不整合、指標、分析、停止条件は維持した。

調整確認用データで事前基準を満たした後、評価コード、設定、分析手順の版を実行マニフェストへ記録し、固定した。固定後、テスト分割を一度だけ実行した。評価中に生成モデルや外部モデルは呼び出していない。

5.6 指標と統計分析

主指標は**不整合流出率**と**妥当更新受理率**である。前者は注入した不整合候補を受理した割合、後者は参照情報から作った妥当候補を受理した割合を指す。副次指標は、種類の報告率、参照情報を使う復元の成功率、候補当たりの平均検証時間とする。種類の報告率は、注入した種類を報告した件数を全 763 件で割る。復元成功率は、復元を試みた件数と全不整合の件数をそれぞれ分母にして示す。

同じ候補での条件差を計算し、質問テンプレート単位のクラスターブートストラップを 10,000 回行って 95%区間を求める。これにより、一つのテンプレートから派生する候補の依存を保つ。ただし、テンプレートをまたぐ患者、ケース、変異規則の共有による依存は扱わない。区間が表すのは固定した故障モデルと採用テンプレート内の変動であり、自然なエラー率や他施設への一般化の不確かさではない。全クラスタで差が同じなら区間幅は 0 となるが、普遍的な性能の証明にはならない。

5.7 参照情報への依存を調べる探索的な追加評価

正式結果を確認した後に二つの追加評価を設計し、実行前に規則を固定した。第一に、test と validation の保存済み診断コードから、検査項目を外した場合の受理・拒否を再構成した。検査器は該当する問題をすべて集め、残る問題がなければ受理する。そのため判定は再構成できるが、項目を外した検査器の再実行や、診断、復元、実行時間の評価とは区別する。

第二に、test の回答可能な 934 件について、元の SQL、空白を変えた対照、`SELECT * FROM (original) WHERE 1 = 1` で包む別解、`WHERE` 内の列とリテラルの等号を不等号に変える候補を比較した。等号は構文木を深さ優先で走査し、最初に適用できる一箇所を変える。全リテラルと他の SQL 文字列は残す。表示部品は基準のものを保ち、実行結果を実際の SQL へ結び付ける。局所検査への通過は候補の採用条件にしない。

正解判定は、既存のオラクルや結果ダイジェスト関数を使わない比較処理で行う。読み取り専用 SQLite で元と変換後の SQL を実行し、列名と、型・重複を保った結果の多重集合を照合する。包む別解は両者が一致した場合だけ妥当と扱う。等号の反転は列が一致し、結果が異なる場合だけ結果変更として数え、結果が同じ候補は別集計にする。正解 SQL を要求の代理とする技術的な判定であり、医学的な正解ではない。一つのデータベース状態で比較し、行順は評価しない。

構文や読み取り専用検査に失敗する SQL、非決定的な関数、順序指定のない行数制限は除外する。SQL ごとに 5 秒・10,000 行の上限を設け、実行失敗と除外も数える。元 SQL の繰り返し実行で結果の安定性を確認する。受理、問題コード、分母に加え、SQL 一致、注釈照合、両方を外した場合の判定を再構成する。有限のケースを使う探索的評価であり、自然に生じる生成誤りの頻度は推定しない。

5.8 モデルが生成する更新を使う探索的な予備評価

SQL 変換実験の後、別の小規模な生成課題を固定した。合成の体重・脈拍を表示する初期 UI に対し、期間、患者、最新件数、単位、項目、順序、表示方法を変える 20 要求を作った。プロンプトでは明示していない条件と、変更対象外の脈拍ウィジェットを保持するよう指示した。各要求は同じ初期画面からの 1 回の更新であり、連続更新や医療者が作った課題ではない。

Vertex AI 経由の Gemini 2.5 Pro で、SQL と表示仕様の JSON を各要求 1 回生成した。temperature は 0.2、top-p は 1、最大出力は 4,096 トークン、thinking budget は 1,024 トークン、seed は 20260908 から 20260927 とした。修正と再生成は行わない。この小さな形式は既存の Streamlit レンダラを使うが、アプリの更新範囲判定とグラフの増分生成は通さない。モデルへ送ったのは合成のスキーマ、初期 SQL、要求だけであり、目標 SQL と DB の行は渡していない。

構造・実行検査、目標 SQL との厳密な一致と表示条件、要求に応じた結果の検査を 1 状態または 3 状態で行う条件を比較した。結果の検査では、人手で定めた変更・保持条件を Python で解釈し、行順、値、単位、表示先、表示設定を照合する。参照 SQL は利用しない。採点では別の 4 状態に対し、同じ条件から別実装で作る SQL と結果を比べた。全状態に期間の境界と対象外の行を置き、一部は欠損値や指定期間内の測定がない状態とした。要求条件と表示の判定コードは共有し、専門家が独立に確認した正解ではない。有限の状態での一致を SQL の意味同等性とは扱わない。SQL を実行で評価する先行研究があり [12]、新しい一般的な SQL 評価方法としては位置づけない。

返却された出力は JSON 不正も含めて残し、API 障害は別に記録する。条件は正式評価の検査器とは異なり、グラフ形式の効果や母集団の誤り率を調べるものではない。結果を確認した後に追加した簡単な期間条件の診断は、事後の補足として分けて報告する。

5.9 データ管理と再現性

EHRSQL を使う評価の公開成果物には、生データ、質問文、正解 SQL、患者 ID、患者単位の結果値を保存しない。保存するのは、ハッシュ化したケース識別子、入力と候補のチェックサム、不整合の種類、判定、診断、復元、集計、実行環境である。正式結果は JSON と JSON Lines で固定し、別の処理で TSV へ変換して件数、主要指標、95%信頼区間を再計算した。再集計値は元の集計と一致した。別の生成課題では、完全な合成データ、要求、モデル応答、利用トークン、チェックサムを公開する。

Table 3. 成果物内検査を通過した不整合の割合

種類	生成数	流出数	流出率
対象患者	52	51	98.08%
対象項目	55	51	92.73%
期間	106	103	97.17%
集約方法	34	33	97.06%
情報源	134	0	0.00%
表示方法	134	0	0.00%
接続	129	129	100.00%
古い結果	119	0	0.00%
合計	763	367	48.10%

6 結果

6.1 基準ケースと候補

テスト分割には 1,167 件があり、正解 SQL を持つ回答可能ケース 934 件を対象とした。回答不能 233 件は主評価から除外した。934 件すべてで正解 SQL の実行と基準成果物の構築に成功し、82 件は列構造を持つ空結果だった。134 種類の質問テンプレートから 763 組の更新前後ペアを作った。各ペアについて妥当候補と不整合候補を作り、4 条件に入力したため、検査回数は $763 \times 2 \times 4 = 6,104$ 回となった。候補ラベルと参照情報に基づく正解判定の不一致は 0 件だった。

作成した不整合は、対象患者 52 件、対象項目 55 件、期間 106 件、集約方法 34 件、情報源 134 件、表示方法 134 件、接続 129 件、古い結果 119 件の合計 763 件だった。患者、項目、期間、集約では、意味を一つだけ変えられる代替 SQL がない場合に候補化を見送った。候補を作れるかどうかはデータと質問形式に依存するため、8 種類の件数は均等ではない。

候補の構築失敗は延べ 3,420 回で、患者 1,140 回、項目 1,383 回、期間 576 回、集約 321 回だった。他の種類では記録されていない。これは構築の試行回数であり、除外した質問や患者の数ではない。各テンプレートと種類について最初に構築できた組だけを採るため、このデータと手順で表現できる不整合へ対象が偏る。

6.2 RQ1：局所検査を通過する不整合

局所検査は、採用された不整合候補をすべて受理した。これは候補の採用条件を確認する結果であり、局所検査が現実の誤りをすべて見逃すと示した結果ではない。比較で調べるのは、意図的に選んだこれらの不整合を、追加の検査がどこまで捉えるかである。

成果物内検査の流出率は種類によって異なった。表 3 に示すように、追加した三つの検査は、情報源の記録、表示規則、古い結果の不整合をすべて拒否した。一方、患者、項目、期間、集約の不整合は 92.73%から 98.08%が流出し、接続の不整合はすべて流出した。この条件は目標の要求や接続先との一致を調べない。ただし、意味要素の変更によって結果形状や表示規則にも違反し、拒否される候補はあった。

6.3 RQ2：4 条件の検出、受理、種類の報告

主結果を表 4 に示す。グラフ検査と表形式検査は、不整合候補 763 件をすべて拒否し、妥当候補 763 件をすべて受理した。局所検査との流出率の差は −100.00 ポイントで、95%信頼区間は $[-100.00, -100.00]$ だった。成果物内検

Table 4. 4 条件の主結果と副次結果

条件	不整合流出	妥当受理	種類報告	平均時間
局所検査	763/763	763/763	0/763	2.152 ms
成果物内検査	367/763	763/763	387/763	7.441 ms
グラフ検査	0/763	763/763	763/763	9.339 ms
表形式検査	0/763	763/763	763/763	9.296 ms

査との差は −48.10 ポイントで、95%信頼区間は [−49.56, −46.53] だった。妥当更新受理率は 4 条件すべて 100.00% で、条件差は 0 だった。

成果物内検査は 396 件を拒否し、そのうち 387 件で注入した種類を診断に含めた。全 763 件に対する割合は 50.72%だった。二つの層間検査は全件で注入した種類を報告した。この指標は、正確な箇所や診断の過不足を採点した結果ではない。候補当たりの平均検証時間は、局所検査 2.152 ms、成果物内検査 7.441 ms、グラフ検査 9.339 ms、表形式検査 9.296 ms だった。SQL 実行、候補生成、復元、描画は含まない。二つの層間検査の差 0.043 ms は記述値であり、反復実行による性能比較は行っていない。

6.4 RQ3：参照情報を使う一回の復元

局所検査は不整合を拒否せず、復元を試みなかった。成果物内検査は 396 件で復元処理を呼び出し、387 件が同じ検査条件と正解判定を通過した。試行した候補に対する割合は 97.73%、全不整合に対する割合は 50.72%だった。残る 9 件では、診断に注入した種類が含まれず、復元処理は候補を変更しなかった。

二つの層間検査は、保存した妥当なデータ成果物または表示部品を使い、763 件すべてを復元した。復元は種類の報告を条件として既知の妥当部品をコピーするため、成功数は種類の報告結果と結び付いている。未知の誤りを自動修復する能力を独立に示す結果ではない。妥当候補の拒否は 0 件だった。また、この手順は妥当ラベルの候補を誤って拒否しても復元を試みない。

6.5 参照情報への依存に関する追加評価の結果

保存済み診断の再集計では、SQL 一致と注釈照合を片方ずつ外しても、流出は test で 0/763、validation で 0/758 だった。両方を外すと 238/763、237/758 が流出した。成果物内検査に SQL 一致と目標の接続先を加えた条件は、両分割の妥当・不整合候補を合わせた 3,042 候補でグラフ検査と同じ受理・拒否を得た。これは判定だけの再構成であり、診断や保存形式の同等性は測っていない。

SQL 変換実験では、934 件のうち現在時刻の式を含む 286 件を、固定した非決定性の規則で除外した。残る 648 件は 126 種類のテンプレートに対応する。元 SQL と空白の対照は全条件で受理された。包む別解 648 件はすべて列名と型付き結果の多重集合を保ったが、二つの層間検査は `target_query_mismatch` だけを理由にすべて拒否した。これは 5.7 節の結果に基づく基準では誤拒否であり、より厳しい参照表現との一致という契約には従っている。

等号の反転では、適用箇所がない 60 件、列名が変わる 42 件、結果が同じ 70 件を、結果変更として採点しなかった。残る 476 件は 96 種類のテンプレートに対応し、列名を保って結果を変えた。そのうち 147 件は空結果になった。実行失敗と上限到達はなかった。表 5 に採点対象の結果を示す。SQL 一致を外した再構成では 329/476 件が流出した。注釈照合の不一致はなく、残る 147 件の拒否は結果形状の検査による。このうち 143 件は局所検査でも拒否された。

Table 5. 探索的な SQL 変換実験。下の 3 行はグラフの診断コードを除いて判定を再構成したもので、変更した検査器の再実行ではない。別に報告した除外ケースは分母に含めない。

条件	別解の誤拒否	結果変更の流出
局所検査	0/648	333/476
成果物内検査	0/648	329/476
グラフによる層間検査	648/648	0/476
表形式による層間検査	648/648	0/476
グラフの診断から SQL 一致を除く	0/648	329/476
グラフの診断から注釈照合を除く	648/648	0/476
グラフの診断から両方を除く	0/648	329/476

6.6 実生成で保持条件の欠落を確認したが、検査の追加効果は示されなかった

約 194 秒で 20 件すべての応答が返り、JSON 不正はなかった。有限の状態による採点では 18 件が適合した。最新 1 件・3 件の体重を求めた 2 件では日時の下限と上限が消えた。初期画面の 1 日間の範囲と、固定した基準日時を保持する指示に違反し、基準日時より後の合成行が表示された。構造検査は 2 件を通したが、1 状態・3 状態での結果の検査は両方を拒否し、適合 18 件を受理した。参照 SQL との一致は適合 3 件も拒否した。2 件は REAL 列に掛ける整数定数と小数定数の表記差、1 件は同名の別名指定の省略だった。

この失敗を見た後、SQL の構文木で必須の日時条件を確認し、構造検査と合わせる診断を追加した。20 件すべてで、結果を使う二つの検査と判定が一致した。この診断は患者や単位、任意の SQL 形式を検証しない。観測された 2 件が同じ期間保持の失敗であるため、簡単な検査に対する追加の識別能力と、データ状態を増やす効果は示されなかった。これは解釈を限定する事後の診断であり、事前に計画した比較ではない。

全 20 件はアプリ内の例外・警告なく描画された。表 39 個と折れ線グラフ 1 個へ渡されたデータを SQL の結果と照合し、表示列とグラフの軸も確認した。要求違反の 2 件も正常に描画されるため、描画できることと要求への適合は一致しない。確認したのは描画データであり、視認性や臨床的な正しさではない。この予備評価は保持条件が消える具体例と参照一致の制約を示すが、一般的な頑健性の証拠にはならない。

7 考察

7.1 統制した比較から分かること

本評価は、目標の正解を知っている条件で、実装した検査の範囲を調べる。成果物内検査は、情報源メタデータ、基準の表示種類、SQL と結果版の不一致を捉えた。SQL の意味要素を変えた結果、形状も変わって拒否される場合があるが、その診断が注入した種類を示すとは限らない。二つの層間検査は目標 SQL と接続先も調べ、採用した不整合をすべて拒否した。

これは実装した故障モデルに対する検査範囲の結果である。変異を作る側と検査を設計する側は、変える関係と保つ関係を知っている。診断の再集計では SQL 一致と注釈照合の役割が重なったが、追加の SQL 変換実験では違いが現れた。SQL 一致は結果を保つ別解を拒否し、それを外して注釈照合を残した判定は、結果を変える 329 件を見逃した。SQL 一致を外すだけでは十分な修正にならない。現行の目標結果の比較も、参照と SQL 版が一致する場合に限られる。許容する問い合わせと結果の範囲を契約に定め、設計に使わなかったケースで評価する必要がある。

7.2 更新を検査するための期待値をどこから得るか

実用上の課題は、信頼できる期待値の入手方法である。保存した接続先や SQL と結果の版は参照できても、新しい自然言語要求に対する正しい SQL を知っているとは限らない。本評価の層間検査には両方を渡している。期待値と出力を同じ生成モデルで作れば、互いには整合していても、要求に対して両方が誤る場合がある。この問題は今回の評価で解決していない。

開発者は、故障モデルを使って、検査に必要な参照項目と検出対象を明示できる。情報源の記録が SQL と一致しないことと、SQL が不適切な情報源を問い合わせることは異なる。基準の表示規則への違反と、利用者を誤らせる表示も異なる。これらを区別して報告し、拒否件数をまとめて臨床的な正しさの根拠にしないことが、本評価から得られる設計上の示唆である。

7.3 グラフと表の結果が一致した理由

二つの層間検査は同じ契約を使い、SQL、データ、表示部品の検査関数を共有する。一致した結果が示すのは、今回の候補では二つの参照経路が同じ判定に至ったということまでである。保存形式によらない性能、大規模なグラフ更新の伝播、いずれかの表現の優位性は判断できない。それらを調べるには、独立した実装と、対象の作業に応じた測定が必要になる。

生成 UI の先行研究は、中間表現を利用者が内容を確かめ、編集するために使う [2, 6, 9]。本評価は、既知の基準とデータの対応を調べる開発者向けの問題に範囲を絞る。その検査によって、人が生成 UI を確認・編集しやすくなるかは残る課題である。

7.4 生成 UI への適用を評価する

本評価基盤は、開発者が回帰テストに使うことを想定している。生成時の検査へ広げるには、自然に生成された誤りと、信頼できる期待値を入手できるかを調べる必要がある。動機を説明する診療シナリオだけでは、8 種類の不整合の頻度や実務上の重要性は分からない。

技術評価を進める場合は、検査器を固定してから自然に生成された更新を集め、妥当な別解も含め、検査器の設計から独立した正解判断と既存手法との比較を行う。医療者の確認作業を貢献とする場合は、専門家が確認したシナリオを使い、同じ画面で診断の有無を比べる。不整合の誤受理、妥当候補の受理、確認時間、修正の正しさを分けて測る必要がある。効果の有無と、診断によって増える負担の両方を確かめる。

7.5 復元と未知の誤りの修正を分ける

保存した妥当成果物のコピーは、信頼できる目標状態がある場合の復元には使える。しかし、未知の生成状態から正しい状態を見つける処理ではない。本評価では注入した種類も渡し、最小差分を計算せず、データ成果物または表示部品全体を置き換える。実用的な修復能力を評価するには、注入情報と妥当な目標成果物を渡さず、他の情報を壊していないかと修正後の正しさを独立に確認する必要がある。復元成功率 100%を、診断だけで自動修復できる根拠としては扱えない。

8 制約と倫理

第一に、本評価では、同じ入力から同じ不整合を作る規則を使い、一つずつ注入した。そのため、生成モデルが自然に起こすエラーの分布は表していない。単一故障で 100%を得た条件が、複合故障、曖昧な要求、未知の表示部品でも同じ性能を持つとは限らない。今後は、固定した検査を生成モデルが作った候補に適用し、今回の分類に含まれない失敗を質的に調べる必要がある。

第二に、更新前だけでなく、更新後の正しい SQL とその実行結果を使う。要求された更新の信頼できる目標状態があるという前提は、生成 UI への適用を強く制限する。質問の解釈、初回生成、棄権、妥当な別解への対応は別に評価する必要がある。

第三に、正式評価では MIMIC-IV Demo v2.2 と EHRSQL-2024 の質問テンプレートを使った。麻酔科術前外来と甲状腺術後フォローは問題設定を説明する設計例であり、正式評価ケースではない。結果形状や利用可能な代替条件により、不整合ごとの候補数は異なる。他の診療シナリオ、データモデル、複数施設、複雑な可視化、複数データ源をまたぐ更新に結果を一般化できない。医療以外のデータや業務への適用も評価していない。

第四に、層間検査と正解判定は目標の参照情報を共有し、グラフ検査と表形式検査は主要関数も共有する。そのため、判定の一致から得られる証拠は限られる。探索的な診断除去は受理・拒否だけを扱う。SQL 変換実験は一種類の包む規則と等号反転を、一つのデータベース状態で調べた。現在時刻を使う 286 件を除外し、行順は比較していない。正解の比較処理は元のオラクルとダイジェストを使わないが、参照 SQL と SQLite エンジンは共通している。観測した誤拒否や流出の件数から、自然に生成された SQL や意味が同じすべての UI に対する性能は推定できない。

第五に、本研究は匿名化済み公開デモデータと完全な合成データを使う技術評価である。正解 SQL は技術的な基準であり、表示内容の医学的妥当性を専門家が確認した正解ではない。層間整合性が確認負担、誤った更新の受理、診療判断へ与える影響も測っていない。臨床上の安全性、診療判断の正確さ、使いやすさ、認知負荷、臨床転帰、実運用、他施設への一般化は評価していない。人を対象とする評価は、倫理審査と実施許可、募集、同意、撤回、データ管理を確認した後の別研究とする。

EHRSQL を使う評価の公開成果物には、質問文、正解 SQL、患者 ID、患者単位の結果値を含めない。MIMIC-IV Demo と EHRSQL-2024 の利用条件と出典を明記し、公開可能なチェックサム、分類、判定、集計だけを再現資料へ含める。

生成課題の予備評価は、1 モデル・各要求 1 回で、出力形式と人手で定めた要求条件を限定している。実アプリ全体の生成処理は通さない。失敗 2 件は同じ種類の要求に属し、事後に追加した期間条件の検査で同じ判定となった。要求仕様と表示の検査を共有するため、採点の独立性も限られる。強い既存検査に対する検出の改善、任意の同等なプログラムへの対応、医療者への便益は示していない。

9 結論

本研究は、臨床 UI の更新における要求、SQL、結果、表示の対応を、既知の参照情報で調べる回帰テストの基盤を示した。EHRSQL-2024 と MIMIC-IV Demo を使い、8 種類の規則から 763 組の更新を構築し、6,104 回の検査を行った。候補の採用条件、比較する項目、診断の採点、復元へ渡す情報を明示した。

不整合候補は構築条件によって局所検査をすべて通過し、成果物内検査でも 48.10%が受理された。二つの層間検査は、目標情報と検査関数を共有し、不整合をすべて拒否して参照情報から作った妥当候補をすべて受理した。この結果は、定義した故障モデルに対する検査範囲を示す。種類の報告と保存済みの妥当部品のコピーから、未知の生成状態の問題箇所を特定し、自動修復できるとは判断できない。

探索的な追加評価では、正式評価の候補だけでは見えなかった制約が現れた。層間検査は結果を保つ SQL の別解 648 件を拒否し、SQL 一致を外した判定は結果を変える 476 件のうち 329 件を受理した。実用上は、信頼できる期待値の入手方法と、許容する別解と情報の変更を区別する方法が課題になる。契約を広げる場合は、設計に使わなかったケースと自然に生成された更新で、独立した正解判断との対応を評価する必要がある。この検査が人による UI の確認や修正を支えられるかは、今後確かめる課題として残る。

別の生成課題 20 件では、期間条件が消える 2 件と、参照一致が適合候補を拒否する 3 件を確認した。ただし、事後に追加した簡単な検査と判定が一致し、データ状態を増やす効果も出なかった。次の評価では実アプリの生成処理を対象に、保持条件の検査が簡単な検査へ何を追加するのかを確かめる必要がある。

REFERENCES

[1] Earl T. Barr, Mark Harman, Phil McMinn, Muzammil Shahbaz, and Shin Yoo. 2015. The Oracle Problem in Software Testing: A Survey. *IEEE Transactions on Software Engineering* 41, 5 (2015), 507–525. https://doi.org/10.1109/TSE.2014.2372785

[2] Yining Cao, Peiling Jiang, and Haijun Xia. 2025. Generative and Malleable User Interfaces with Generative and Evolving Task-Driven Data Model. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 686, 20 pages. https://doi.org/10.1145/3706598.3713285

[3] J. Nathan Foster, Michael B. Greenwald, Jonathan T. Moore, Benjamin C. Pierce, and Alan Schmitt. 2007. Combinators for Bidirectional Tree Transformations: A Linguistic Approach to the View-Update Problem. *ACM Transactions on Programming Languages and Systems* 29, 3, Article 17 (2007). https://doi.org/10.1145/1232420.1232424

[4] Xiao He, Xing Chen, Sibo Cai, Ying Zhang, and Gang Huang. 2018. Testing Bidirectional Model Transformation Using Metamorphic Testing. *Information and Software Technology* 104 (2018), 109–129. https://doi.org/10.1016/j.infsof.2018.07.010

[5] Alistair Johnson, Lucas Bulgarelli, Tom Pollard, Steven Horng, Leo Anthony Celi, and Roger Mark. 2023. MIMIC-IV Clinical Database Demo. *PhysioNet* (2023). https://doi.org/10.13026/dp1f-ex47 Version 2.2.

[6] Zoe Kaputa, Anika Rajaram, Vryan Feliciano, Zhuoyue Lyu, Maneesh Agrawala, and Hariharan Subramonyam. 2026. SimStep: Human-in-the-Loop Authoring of Interactive Educational Simulations Through Task-Level Abstractions. In *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 75, 34 pages. https://doi.org/10.1145/3772318.3791514

[7] Gyubok Lee, Sunjun Kweon, Seongsu Bae, and Edward Choi. 2024. Overview of the EHRSQL 2024 Shared Task on Reliable Text-to-SQL Modeling on Electronic Health Records. In *Proceedings of the 6th Clinical Natural Language Processing Workshop*. Association for Computational Linguistics, Mexico City, Mexico, 644–654. https://doi.org/10.18653/v1/2024.clinicalnlp-1.62

[8] Damien Masson, Sylvain Malacria, Géry Casiez, and Daniel Vogel. 2024. DirectGPT: A Direct Manipulation Interface to Interact with Large Language Models. In *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 975, 16 pages. https://doi.org/10.1145/3613904.3642462

[9] Seokhyeon Park, Soohyun Lee, Eugene Choi, Hyunwoo Kim, Minkyu Kweon, Yumin Song, and Jinwook Seo. 2026. Bridging Gulfs in UI Generation through Semantic Guidance. In *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 880, 16 pages. https://doi.org/10.1145/3772318.3791966

[10] Venkatesh Sivaraman, Leigh A. Bukowski, Joel Levin, Jeremy M. Kahn, and Adam Perer. 2023. Ignore, Trust, or Negotiate: Understanding Clinician Acceptance of AI-Based Treatment Recommendations in Health Care. In *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 754, 18 pages. https://doi.org/10.1145/3544548.3581075

[11] Priyan Vaithilingam, Elena L. Glassman, Jeevana Priya Inala, and Chenglong Wang. 2024. DynaVis: Dynamically Synthesized UI Widgets for Visualization Editing. In *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 217, 17 pages. https://doi.org/10.1145/3613904.3642639

[12] Ruiqi Zhong, Tao Yu, and Dan Klein. 2020. Semantic Evaluation for Text-to-SQL with Distilled Test Suites. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. Association for Computational Linguistics, 396–411. https://doi.org/10.18653/v1/2020.emnlp-main.29