

生成臨床 UI の更新における層間整合性の評価

ANONYMOUS AUTHOR(S)

生成 AI でデータ駆動型 UI を更新すると、SQL と画面が個別に動作しても、利用者の情報要求、SQL、実行結果、表示の対応が壊れることがある。本研究は、この層間不整合を検出・特定・修復するための評価基盤を示す。EHRSQL-2024 と MIMIC-IV Demo を用いて、8 種類の不整合を決定的に生成し、局所検査、成果物ごとの契約、質問から表示までを結ぶグラフ契約、同じ内容を平坦に保持する契約を比較した。固定後のテストでは、134 種類の質問テンプレートから 763 組を作り、6,104 回検証した。局所検査と成果物ごとの契約は、不整合のそれぞれ 100.00% と 48.10% を受理した。グラフ契約と平坦な契約は不整合をすべて拒否し、妥当な更新をすべて受理した。両者の差が 0 だったことから、検出を支えたのはグラフ形式そのものではなく、層をまたぐ対応関係を実行可能な契約として保持したことだと分かった。この結果を基に、生成 UI へ検査可能な追跡情報と更新時の診断を組み込む設計指針を示す。

CCS Concepts: • **Human-centered computing** → **Human computer interaction (HCI)**; *Interactive systems and tools*.

Additional Key Words and Phrases: 生成ユーザーインターフェース, データ駆動型 UI, 電子カルテ, 整合性検査, 増分更新, 追跡可能性

ACM Reference Format:

Anonymous Author(s). 2027. 生成臨床 UI の更新における層間整合性の評価. In *Proceedings of Proceedings of the 2027 CHI Conference on Human Factors in Computing Systems (CHI '27)*. ACM, New York, NY, USA, 11 pages. <https://doi.org/10.1145/nnnnnnnn.nnnnnnnn>

1 はじめに

生成 AI を使うと、利用者の目的に合わせて画面を作り、その後の要求に応じて構成やデータ取得を更新できる。医療のように情報が複数の表や画面へ分散する場面では、診療タスクに必要な患者、項目、期間、集約方法だけを選び、適切な表示へまとめる UI が考えられる。しかし、生成後の更新には、画面が表示できるかだけでは判断できない問題がある。

例として、利用者が「対象患者の直近 24 時間の腎機能を数値で表示する」と依頼し、その後に対象患者を変更した場合を考える。SQL だけが以前の患者を参照する、24 時間の条件だけが外れる、SQL を更新しても実行結果が以前のままだと残る、といった更新が起こり得る。これらの SQL は構文上正しく、読み取り専用で実行できる。結果と表示部品もそれぞれ妥当な形式であり、画面の描画にも成功する。それでも、利用者が求めた情報と表示値の対応は壊れている。

本稿では、利用者の情報要求、SQL、実行結果、表示部品の間で意味上の対応が壊れた状態を**層間不整合**と呼ぶ。層間不整合は、一つの成果物に閉じた検査では見つからない場合がある。SQL の構文検査は、質問と SQL が同じ患者や期間を指すかを保証しない。表示部品の型検査は、その部品が更新後の実行結果を参照しているかを保証しない。生成 UI を更新可能なシステムとして扱うには、成果物の生成に加えて、層をまたぐ関係を更新後も検査できる必要がある。

生成・編集可能な UI の研究では、タスクモデルや意味表現を介して自然言語要求と UI を結ぶ方法が示されている。Jelly は、変化する情報タスクをタスク駆動データモデルとして保持し、自然言語と直接操作による更新を支える [1]。Bridging Gulfs は、設計意図の意味表現を利用者の入力と生成 UI の間に置き、解釈を確かめながら生成できるようにする [8]。SimStep は複数のタスクレベル表現を使い、生成結果の前提を段階的に確認・修正できるようにする [5]。これらは中間表現の価値を示す一方、データ取得を伴う UI の増分更新で、情報要求から表示までのどの関係が壊れ、どの検査で見つかるかを同一候補上で比較していない。

2027. Manuscript submitted to ACM

そこで本研究は、生成臨床 UI の更新における層間不整合を評価する基盤を構築した。臨床情報要求と正解 SQL を収録する EHRSQL-2024[6] を、公開デモ用の MIMIC-IV Clinical Database Demo v2.2[4] 上で実行し、基準となるデータ駆動型 UI を作る。そこへ対象患者、対象項目、期間、集約方法、情報源、表示方式、データと表示の接続、更新後に残る古い結果という 8 種類の不整合を一つずつ入れる。候補生成とは独立した処理で正解を判定し、同じ候補を 4 種類の検査条件へ入力する。

本研究では次の問いに答える。

RQ1 SQL や表示部品を一つずつ確認するだけでは見つからない層間不整合には、どのような種類があるか。

RQ2 局所検査、成果物ごとの契約、質問から表示までをまとめて確認する契約では、不整合の見逃し、妥当な更新の受理、問題箇所の特定がどう異なるか。

RQ3 検査で特定した問題を一回だけ自動修復すると、どの範囲を直せるか。

固定した評価方法でテスト分割を一度だけ実行した結果、134 種類の質問テンプレートから 763 組を作り、4 条件で妥当候補と不整合候補を検査する合計 6,104 回の評価を得た。局所検査は不整合 763 件をすべて受理し、成果物ごとの契約も 367 件を受理した。質問から表示までを結ぶグラフ契約と、同じ対応内容を一枚の平坦な表に保持する契約は、不整合をすべて拒否し、妥当候補をすべて受理した。両者は判定、問題箇所の特定、一回の修復で同じ結果だった。これは、グラフという保存形式に検出上の優位性があるという予想を支持しない。層をまたぐ意味関係を明示し、実行可能な契約として検査したことが結果を分けた。

本稿の貢献は次の四点である。

- データ駆動型 UI の増分更新で起こる層間不整合を、患者、項目、期間、集約、情報源、表示方式、接続、古い結果の 8 種類として操作可能に定義した。
- 公開デモデータ上で不整合を決定的に生成し、候補生成とは独立したオラクルで確認する再現可能な評価方法を示した。
- 同じ候補に 4 種類の検査条件を適用し、個別成果物の妥当性だけでは層間整合性を保証できない範囲を定量化した。
- グラフ契約と同じ内容を持つ平坦な契約が同じ結果を得たという否定的結果から、生成 UI に必要なのは特定の保存形式ではなく、検査可能な層間関係であるという設計上の含意を導いた。

本評価は技術評価であり、臨床上の安全性、診療判断の正確さ、使いやすさ、認知負荷、臨床転帰を評価していない。この境界を保ったうえで、生成 UI 研究における更新の正しさを、最終画面の品質とは別の評価対象として位置付ける。

2 関連研究

2.1 生成・編集可能な UI

生成 UI の研究は、自然言語や例示から画面を生成する段階から、生成物を利用者が理解し、編集し、再利用できる段階へ広がっている。DirectGPT は、会話だけでなく生成物そのものを直接操作し、参照解決を支えることで、生成 AI との反復的な作業を扱った [7]。DynaVis は、可視化の生成と編集を対話的に行い、生成された UI 上の操作を自然言語対話と組み合わせた [10]。これらの研究は、生成物を一回限りの出力ではなく、継続的に変更される対話対象として扱う。

更新可能性を支えるため、中間表現を導入する研究もある。Jelly は、タスク駆動データモデルを生成 UI の背後へ置き、タスクの変化をデータと画面へ反映する [1]。Bridging Gulfs は、意味表現を通じて利用者の意図、生成モデルの解釈、出力 UI の隔たりを小さくする [8]。SimStep は、概念、シナリオ、学習目標、UI のグラフを分け、人が各段階の仮定を編集できるようにする [5]。これらの設計では、中間表現が検査や修正の接点になる。

本研究は、より狭い問いを扱う。UI の生成品質や編集体験を比較するのではなく、更新前後でデータの意味関係が保たれたかを検査する。中間表現を利用するが、グラフ形式そのものを貢献とはしない。同じ関係を平坦な形式でも表し、検出結果を比較することで、形式と確認内容を分けて評価する。

2.2 人と生成システムの協働における検査と修正

生成システムの利用者は、出力を単純に採用または拒否するだけではない。Ignore, Trust, or Negotiate は、生成 AI の提案を利用者が無視、信頼、交渉しながら取り込む過程を示し、提案の不確かさや根拠を扱う相互作用の必要性を論じた [9]。生成 UI でも、エラー表示だけで更新全体を拒否するより、どの関係が壊れ、何を修正すると影響がどこへ及ぶかを提示する方が、利用者の判断を支えられる可能性がある。

デバッグ支援では、失敗の有無だけでなく原因へ到達できることが重要である。本研究は、検出、問題箇所の特定、一回の自動修復を別々に測る。これにより、拒否率だけが低い検査と、修正可能な診断を返す検査を区別する。ただし、本稿は診断表示を人が理解できるかを評価していない。技術的に特定できることと、人の判断を支えられることは別の研究課題として扱う。

2.3 自然言語質問からデータ取得と表示まで

Text-to-SQL 研究は、自然言語質問から実行可能な SQL を生成し、質問へ正しく答えられるかを評価してきた。EHRSQL-2024 は電子カルテを対象に、回答可能な質問と回答不能な質問を含む共有タスクを提供する [6]。この評価では、質問に対応する SQL を生成できるか、答えられない質問で棄権できるかが中心になる。

本研究は SQL 生成性能を比較しない。正解 SQL を基準として使い、その後に生じる層間不整合を扱う。正しい SQL が一度得られても、UI 更新時に質問だけ、SQL だけ、結果だけ、表示だけが別の版へ進む可能性がある。また、実行可能な SQL へ変更されても、対象患者や期間が要求とずれる場合がある。したがって、質問と SQL の対応に加えて、SQL と実行結果、結果と表示方式、データ取得と表示部品の接続、更新版の一致を検査する必要がある。

2.4 モデル変換と整合性

構造化データとビューの更新を対応付ける問題は、双方向変換の研究で扱われてきた。Lens は、元データとビューの往復変換が満たす性質を定式化する [2]。また、完全な正解出力を列挙しにくいモデル変換に対し、不変関係を使うメタモルフィックテストが提案されている [3]。本研究も、完成した UI JSON の完全一致ではなく、変更すべき関係と保持すべき関係を述語として表す。

従来の整合性検査と本研究の違いは、生成 UI の更新を評価するために、利用者の自然言語要求、データ取得、実行結果、表示の境界を同じ評価単位へ含める点にある。完全一致を避けることで、表示文言や安定 ID など意味を変えない差を許しつつ、見た目には現れない患者や期間のずれを不整合として扱う。

3 層間整合性の定義

3.1 対象とする情報の流れ

図 1 に、本研究が扱う 4 層を示す。情報要求は、対象患者、対象項目、期間、集約、情報源、期待する表示方式を含む。SQL は要求をデータベース操作へ変換する。実行結果は SQL、入力、実行時点に対応する版を持つ。表示部品は、結果を参照し、その形状に適した方法で提示する。

更新候補 c が層間整合性を満たすとは、要求と SQL の意味が一致し、SQL と実行結果の版が一致し、結果と表示部品の参照および表示方式が一致することとする。これを次の述語の論理積で表す。




Fig. 1. 層間整合性として検査する情報の流れ。各箱が単独で妥当でも、矢印で表した対応が壊れる場合がある。

Table 1. 評価で生成する 8 種類の層間不整合

種類	変更するもの	単独では通り得る検査
対象患者	SQL の患者条件	構文、読み取り専用、実行
対象項目	取得列または集約対象	構文、実行、結果型
期間	時点・期間条件	構文、実行
集約方法	件数、最大、最小、平均など	構文、実行、結果型
情報源	参照表	構文、実行
表示方式	結果を示す部品の種類	UI 構造、描画
接続	部品が参照するデータ取得	個別ノードの型
古い結果	SQL 更新後の結果版	SQL 実行可能性、結果型、描画

$$I(c) = P(c) \wedge D(c) \wedge T(c) \wedge A(c) \wedge S(c) \wedge V(c) \wedge L(c) \wedge R(c) \quad (1)$$

P は患者、 D は項目、 T は期間、 A は集約、 S は情報源、 V は表示方式、 L はデータと表示の接続、 R は SQL と実行結果の版の一致を表す。候補生成では、妥当候補は 8 述語をすべて満たし、不整合候補は一つだけ満たさないようにする。

3.2 8 種類の不整合

表 1 に不整合の定義を示す。対象患者の不整合では、要求側の患者を保ったまま SQL の患者条件を別の候補へ変える。対象項目では、要求と異なる列または集約対象を取得する。期間では、要求の時点や期間に対応する条件を変える。集約方法では、件数、最大、最小、平均などを別の演算へ置き換える。

情報源の不整合では、要求が対応付けられた表と SQL の参照表をずらす。表示方式では、SQL、実行結果、列、値を保ったまま、基準が数値カードならデータフレーム表示へ、基準がデータフレーム表示なら別の表部品へ変える。接続では、表示部品が別のデータノードを参照する。古い結果では、SQL を更新しても実行結果の版を以前のまま残す。

これらは臨床現場で観測したエラー頻度の分類ではない。どの関係を検査する必要があるかを測定可能にするための故障モデルである。各候補には一種類だけを注入するため、結果は複合故障への性能を示さない。

4 評価基盤

4.1 基準ケースの構築

入力 EHRSQ-2024 の回答可能な質問と正解 SQL である。回答不能ケースは正解 SQL から基準 UI を構築できないため、主評価から除外し、件数を記録する。正解 SQL は MIMIC-IV Demo v2.2 の SQLite データベースへ読み

Table 2. 比較する 4 種類の検査条件

条件	個別成果物	層間関係	保存形式
局所検査	基本検査	なし	各成果物
成果物契約	詳細検査	一部	各成果物
グラフ契約	詳細検査	すべて	ノードと辺
平坦契約	詳細検査	すべて	一枚の表

取り専用で実行する。書き込みを含む文、複数文、許可しない構文は実行前に拒否し、SQL ごとの実行上限を 5 秒とした。

実行結果が単一値なら数値カード、複数行または複数列ならデータフレーム表示を基準とする。空結果は除外せず、列構造を持つ結果として扱う。基準ケースは、質問テンプレートから抽出した意味スロット、SQL の解析結果、結果形状、データノード、表示部品、各成果物の版を保持する。

同じ質問テンプレートと SQL 構造を共有するケースを更新前後として組み合わせる。この組から、すべての関係を同時に更新した妥当候補と、一つの関係だけを壊した不整合候補を作る。同じ質問形式から派生する候補は独立ではないため、後の統計処理では質問テンプレートを再標準化の単位とする。

4.2 独立したオラクル

候補生成と正解判定は別の処理で実装した。オラクルは、質問テンプレートの意味スロット、SQL の解析結果、実行結果の形状と版、データノードと表示部品の参照を照合する。候補生成器が付けた期待ラベルとオラクルの判定が一致しない場合、評価を停止する。

完成した JSON の完全一致を正解としない。安定 ID、順序、表示文言など、意味を変えない差を許すためである。一方、画面の見た目が同じでも、別患者、異なる期間、古い結果を参照する候補は不整合とする。この設計により、表層的な一致と意味上の対応を分ける。

4.3 4 種類の検査条件

同一候補を表 2 の 4 条件へ入力する。局所検査は、SQL が読み取り専用で実行可能か、成果物がスキーマに適合するか、表示部品が描画可能な型かを個別に確認する。成果物契約は、SQL、実行結果、表示部品のそれぞれに条件を追加するが、情報要求から表示までを横断する単一の関係は持たない。

グラフ契約は、質問テンプレート、SQL、結果、データノード、表示部品をノードとし、患者、項目、期間、集約、情報源、版、参照、表示方式の関係を辺として保持する。候補更新後に、影響を受ける関係を再評価する。平坦契約は、グラフと同じ意味スロットと対応関係を一枚のサイドカー表に保持し、同じ述語を検査する。二条件の内容をそろえることで、確認内容の効果とグラフ形式の効果に分ける。

4.4 診断と一回の修復

検査が候補を拒否した場合、失敗した述語と関係する成果物を診断として返す。特定率は、注入した不整合の種類を診断が正しく示した割合とする。検出しただけで、場所または種類を誤った場合は特定成功に数えない。

修復は診断を一回だけ使い、基準契約から一意に定まる値を戻す。たとえば、表示部品の参照先、結果版、表示方式は、対応する契約から復元する。修復後の候補をオラクルと同じ整合性述語で再検査し、すべてを満たした場合だけ成功とする。探索、複数回の試行、生成モデルによる書き換えは行わない。




Fig. 2. 基準ケースの構築から候補生成、検査、診断、修復までの評価手順。

4.5 評価手順

図 2 に評価手順を示す。開発用データでは、異なる質問テンプレートを優先した 50 件で SQL 実行と基準ケースへの変換を確認した。調整確認用データでは、不整合ごとの候補数、質問テンプレート数、ラベル一致、機微情報を保存しない条件を確認した。列順の不整合が生成できなかったため、テスト分割を見る前に表示方式の不整合へ置き換えた。他の不整合、指標、分析、停止条件は維持した。

調整確認用データで事前基準を満たした後、評価コード、設定、分析を Git commit baa82075b6bf で固定した。固定後、テスト分割を一度だけ実行した。評価中に生成モデルや外部モデルは呼び出していない。

4.6 指標と統計分析

主指標は不整合流出率と妥当更新受理率である。不整合流出率は、注入した不整合候補のうち検査が受理した割合であり、低いほどよい。妥当更新受理率は、すべての関係を正しく更新した候補のうち受理した割合であり、高いほどよい。副次指標として、問題箇所の特定制率、一回の修復成功率、候補当たりの平均検証時間を測る。

条件差は同じ候補に対する対応差として計算する。95%信頼区間は、質問テンプレート単位のクラスターブートストラップを 10,000 回行って求める。候補単位ではなく質問テンプレート単位で再標本化するのは、同じ SQL 構造と変異規則を共有する派生候補を独立例として扱わないためである。

4.7 データ管理と再現性

公開成果物には、生データ、質問文、正解 SQL、患者 ID、患者単位の結果値を保存しない。保存するのは、ハッシュ化したケース識別子、入力と候補のチェックサム、不整合の種類、判定、診断、修復、集計、実行環境である。正式結果は JSON と JSON Lines で固定し、別の処理で TSV へ変換して件数、主要指標、95%信頼区間を再計算した。再集計値は元の集計と一致した。

5 結果

5.1 基準ケースと候補

テスト分割には 1,167 件があり、正解 SQL を持つ回答可能ケース 934 件を対象とした。回答不能 233 件は主評価から除外した。934 件すべてで正解 SQL の実行と基準成果物の構築に成功し、82 件は列構造を持つ空結果だった。134 種類の質問テンプレートから 763 組の更新前後ペアを作った。各ペアについて妥当候補と不整合候補を

Table 3. 不整合の種類別に見た成果物契約の流出率

種類	生成数	流出数	流出率
対象患者	52	51	98.08%
対象項目	55	51	92.73%
期間	106	103	97.17%
集約方法	34	33	97.06%
情報源	134	0	0.00%
表示方式	134	0	0.00%
接続	129	129	100.00%
古い結果	119	0	0.00%
合計	763	367	48.10%

作り、4 条件へ入力したため、検査回数は $763 \times 2 \times 4 = 6,104$ 回となった。候補ラベルと独立オラクルの不一致は 0 件だった。

不整合の生成数は、対象患者 52 件、対象項目 55 件、期間 106 件、集約方法 34 件、情報源 134 件、表示方式 134 件、接続 129 件、古い結果 119 件であり、合計 763 件だった。患者、項目、期間、集約では、意味を一つだけ変えられる代替 SQL がいない場合に候補化を見送った。この生成可否はデータと質問形式に依存するため、8 種類の件数は均等ではない。

5.2 RQ1：局所検査を通過する不整合

局所検査は 8 種類すべての不整合候補を受理し、不整合流出率は 100.00% だった。各候補は、読み取り専用 SQL として実行でき、結果と表示部品も個別には有効になるよう構成されている。この結果は、対象患者や期間の誤りだけでなく、表示方式、接続、古い結果も、構文、スキーマ、描画可能性を個別に確かめるだけでは検出できないことを示す。

成果物契約の流出率は不整合の種類で異なった。表 3 に示すように、情報源、表示方式、古い結果はすべて拒否した。一方、患者、項目、期間、集約の不整合は 92.73% から 98.08% が流出し、接続の不整合はすべて流出した。各成果物の内部に記述できる条件は検査できても、要求と SQL、データノードと表示部品のように成果物をまたぐ対応が弱点として残った。

5.3 RQ2：4 条件の検出、受理、特定

主結果を表 4 に示す。グラフ契約と平坦契約は、不整合候補 763 件をすべて拒否し、妥当候補 763 件をすべて受理した。局所検査との差は -100.00 ポイントで、95%信頼区間は $[-100.00, -100.00]$ だった。成果物契約との差は -48.10 ポイントで、95%信頼区間は $[-49.56, -46.53]$ だった。妥当更新受理率は 4 条件すべて 100.00% で、条件差は 0 だった。

成果物契約は、不整合 396 件を拒否したうち 387 件で注入箇所を正しく特定し、特定率は 50.72% だった。グラフ契約と平坦契約は 763 件すべてで種類と箇所を特定した。両条件の判定不一致は 0 件であり、不整合流出率の差も 0 ポイントだった。候補当たりの平均検証時間は、局所検査 2.152 ms、成果物契約 7.441 ms、グラフ契約 9.339 ms、平坦契約 9.296 ms だった。この評価環境では、層間関係を検査する二条件の時間差は 0.043 ms だった。

Table 4. 4 条件の主結果と副次結果

条件	不整合流出	妥当受理	特定	平均時間
局所検査	763/763	763/763	0/763	2.152 ms
成果物契約	367/763	763/763	387/763	7.441 ms
グラフ契約	0/763	763/763	763/763	9.339 ms
平坦契約	0/763	763/763	763/763	9.296 ms

5.4 RQ3：一回の修復

局所検査は不整合を検出しないため、修復を試行しなかった。成果物契約は拒否した 396 件へ一回の修復を試み、387 件が独立オラクルのすべての述語を満たした。試行した候補に対する成功率は 97.73% である。残る 9 件は一回の修復後も整合性を満たさなかった。

グラフ契約と平坦契約は、不整合 763 件をすべて特定し、一回の修復後に 763 件すべてが整合性を満たした。両条件で不要な拒否はなく、妥当候補に修復は適用されなかった。この 100% は、単一故障、既知の契約、決定的な修復規則という本評価の範囲で得た結果であり、自然発生する複合的な生成誤りへの一般化を示さない。

6 考察

6.1 動作する成果物の組は、正しい UI とは限らない

事前には、局所検査でも SQL や表示方式に関する不整合の一部は拒否されると考えていた。しかし、故障を一つに限定し、各成果物が単独で有効になるよう候補を作ると、8 種類すべてが局所検査を通過した。RQ1 への答えは、患者や期間といった SQL 意味の誤りに限られない。表示部品が別のデータを参照する接続誤りや、更新前の結果を表示する版の誤りも、最終画面を構成する各要素が個別に有効なまま起こる。

この結果は、生成 UI の評価単位を広げる必要性を示す。UI コードのコンパイル成功、SQL の実行成功、画面の描画成功は、それぞれ重要な下限条件である。しかし、利用者の依頼へ答えているかを評価するには、要求がどのデータ操作へ変換され、その結果がどの表示へ届いたかを一つの更新として追う必要がある。データに基づく生成 UI では、見た目の品質評価と情報の来歴の評価を分けて報告するべきである。

6.2 成果物契約が捉えたものと捉えられなかったもの

成果物契約は、情報源、表示方式、古い結果をすべて拒否した。これらは、許可表、結果形状と部品型、SQL と結果の版という条件を、個々の成果物へ比較的明確に持たせられたためである。一方、患者、項目、期間、集約の大半と、接続のすべてが流出した。これらは、要求と SQL、またはデータノードと表示部品をまたぐ比較を必要とする。

したがって、型やスキーマを詳しくすれば自動的に層間整合性が得られるわけではない。どの患者、項目、期間を要求から受け継いだかという意味キーと、どの結果をどの部品が参照するかという関係キーが必要になる。成果物ごとの契約は局所的な異常を早く拒否する層として残し、その上に層間契約を重ねる構成が妥当である。

6.3 グラフではなく、関係の内容が効いた

RQ2 で最も重要な結果は、グラフ契約が不整合をすべて拒否したことだけではない。同じ対応内容を持つ平坦契約も同じ結果を得て、両者の差が 0 だったことである。グラフ形式は、影響範囲の探索、部分更新の伝播、複数の表示が同じデータを共有する場合の可視化に適する可能性がある。しかし、本評価はそのような規模や編集体

験を測っていない。検出性能について言えるのは、8 種類の関係を明示的に保持して検査すれば、保存形式がグラフでも平坦な表でも同じ候補を拒否できたということまでである。

この否定的結果は、生成 UI の設計で中間表現を採用するときの説明を変える。グラフを導入した事実を利点として示すのではなく、どの意味関係を保持し、どの更新で再検査し、どの診断を返すかを示す必要がある。実装環境に既存の関係表や来歴表があるなら、検出だけを目的にグラフへ移行する根拠は本結果から得られない。一方、関係の探索や編集、説明のためにグラフが有用かは、別の比較で評価できる。

6.4 診断を更新対話の一部にする

RQ3 では、層間関係をすべて持つ二条件が、単一故障 763 件を一回で修復した。これは、検査を拒否判定のためにだけに使わず、修復に必要な差分を返す設計が可能であることを示す。たとえば「無効な UI」という通知より、「要求の患者と SQL の患者条件が一致しない」「表示部品が更新前の結果版を参照している」という診断の方が、修正対象を限定できる。

ただし、自動修復を無条件に実行するべきだとは結論しない。本評価では、壊れた関係が一つで、契約から正しい値が一意に決まる。自然言語要求が曖昧な場合、臨床的な表示粒度を選ぶ場合、複数の成果物が同時に変わった場合は、一意に修復できないことがある。生成 UI は、機械的に戻せる関係、複数候補を人へ提示する関係、専門家の判断が必要な関係を区別するべきである。

6.5 生成 UI システムへの設計上の含意

本結果から、データ駆動型の生成 UI に次の設計を提案する。

- 情報要求を文字列だけで保存せず、患者、項目、期間、集約、情報源、表示方式を検査可能な意味キーとして保持する。
- SQL、実行結果、表示部品へ同じ版または来歴識別子を伝播し、部分更新後に古い結果が残ったことを検出する。
- 表示部品とデータ取得の接続を暗黙の命名規則に依存させず、明示的な参照として保存する。
- 更新を反映する前に、変更対象だけでなく影響を受ける層間関係を再検査する。
- 拒否理由を述語と成果物の位置へ対応付け、修復可能な場合は最小差分を提示する。
- グラフ、表、JSON などの形式を先に決めず、必要な関係と検査を定義してから保存形式を選ぶ。

これらは電子カルテに限らず、質問からデータを取得してダッシュボード、表、可視化を生成するシステムへ適用できる可能性がある。ただし、領域ごとに情報要求の意味キーと許容される更新が異なるため、8 種類の分類をそのまま一般化するのではなく、領域固有の契約を定める必要がある。

6.6 CHI における生成 UI 評価への示唆

近年の CHI 採択研究は、生成物の品質だけでなく、利用者が生成過程の表現へ働きかけ、解釈を確認し、修正する仕組みを論じている [1, 5, 8]。本研究は、この議論へ技術評価の観点を加える。人が意味表現を編集できても、その表現と実行結果の関係が更新後に検査されなければ、UI は古い値や別の対象を表示し得る。逆に、技術的な契約が完全でも、その診断を人が理解して適切に判断できるとは限らない。

今後の人対象研究では、最終画面だけを提示する条件、層間不整合の種類と影響範囲を提示する条件、修復候補まで提示する条件を比較できる。測るべきなのは、単なる好みだけではない。誤りの検出、適切な修復の選択、不要な修復の回避、根拠の理解、作業時間を分けて評価する必要がある。本稿の評価基盤は、そのような実験で使う故障候補と正解判定を準備する土台になる。

7 制約と倫理

第一に、本評価の不整合は決定的な規則で一つずつ注入したものであり、生成モデルが自然に起こすエラーの分布を表さない。単一故障で 100%を得た条件が、複合故障、曖昧な要求、未知の表示部品でも同じ性能を持つとは限らない。今後は、固定した検査を自然発生候補へ適用し、不整合分類にない失敗を質的に調べる必要がある。

第二に、正解 SQL を出発点としているため、Text-to-SQL モデルの誤りを含まない。実運用では、質問の解釈と SQL 生成も誤り得る。本結果は、正しい基準が得られた後の増分更新に範囲を限定する。質問から SQL を生成する段階を含める場合は、棄権、複数解釈、SQL の臨床的妥当性を別に評価する必要がある。

第三に、MIMIC-IV Demo v2.2 と EHRSQL-2024 の質問テンプレートだけを使った。結果形状や利用可能な代替条件により、不整合ごとの候補数は異なる。他のデータモデル、複数施設、複雑な可視化、複数データ源をまたぐ更新へ結果を一般化できない。

第四に、グラフ契約と平坦契約は同じ対応内容を持つよう意図的に実装した。この比較は保存形式だけを分けるためのものであり、大規模な関係の編集しやすさ、実装保守性、説明の分かりやすさを比較していない。検証時間も一つの実装と環境で測った値であり、形式一般の性能差として解釈できない。

第五に、本研究は匿名化済み公開デモデータ上の技術評価である。正解 SQL は技術的な基準であり、表示内容の医学的妥当性を専門家が確認した正解ではない。臨床上の安全性、診療判断の正確さ、使いやすさ、認知負荷、臨床転帰、実運用、他施設への一般化は評価していない。人を対象とする評価は、倫理審査と実施許可、募集、同意、撤回、データ管理を確認した後の別研究とする。

公開成果物には、質問文、正解 SQL、患者 ID、患者単位の結果値を含めない。MIMIC-IV Demo と EHRSQL-2024 の利用条件と出典を明記し、公開可能なチェックサム、分類、判定、集計だけを再現資料へ含める。

8 結論

生成臨床 UI の増分更新では、SQL、実行結果、表示部品がそれぞれ有効でも、利用者の情報要求から表示までの対応が壊れ得る。本研究は、この層間不整合を 8 種類として定義し、公開デモデータ上で決定的に生成して、4 種類の検査条件を同一候補上で比較した。

763 組、6,104 回の検証では、局所検査が不整合をすべて受理し、成果物契約も 48.10%を受理した。グラフ契約と同じ内容を持つ平坦契約は、不整合をすべて拒否し、妥当な更新をすべて受理した。両者の結果に差がなかったため、検出を支えたのはグラフ形式そのものではなく、患者、項目、期間、集約、情報源、表示方式、接続、版の関係を実行可能な契約として保持したことだと結論付ける。

生成 UI を継続的に更新されるシステムとして設計するには、最終画面の見た目と個別成果物の妥当性に加えて、更新をまたいだ情報の来歴を検査し、問題箇所を説明できる必要がある。本研究は、その評価方法と設計上の境界を示した。次の課題は、自然に生じる複合的な生成誤りへ範囲を広げることと、層間診断が人の確認と修正をどのように支えるかを倫理的に評価することである。

REFERENCES

- [1] Yining Cao, Peiling Jiang, and Haijun Xia. 2025. Generative and Malleable User Interfaces with Generative and Evolving Task-Driven Data Model. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 686, 20 pages. <https://doi.org/10.1145/3706598.3713285>
- [2] J. Nathan Foster, Michael B. Greenwald, Jonathan T. Moore, Benjamin C. Pierce, and Alan Schmitt. 2007. Combinators for Bidirectional Tree Transformations: A Linguistic Approach to the View-Update Problem. *ACM Transactions on Programming Languages and Systems* 29, 3, Article 17 (2007). <https://doi.org/10.1145/1232420.1232424>
- [3] Xiao He, Zhenjiang Li, Zhenjiang Hu, Xiaoyu Liu, and Takashi Hirayama. 2018. Testing Bidirectional Model Transformation Using Metamorphic Testing. *Information and Software Technology* 104 (2018), 48–69. <https://doi.org/10.1016/j.infsof.2018.07.010>

- [4] Alistair Johnson, Lucas Bulgarelli, Tom Pollard, Steven Horng, Leo Anthony Celi, and Roger Mark. 2023. MIMIC-IV. *PhysioNet* (2023). <https://doi.org/10.13026/6mm1-ek67> Version 2.2.
- [5] Zoe Kaputa, Anika Rajaram, Vryan Feliciano, Zhuoyue Lyu, Maneesh Agrawala, and Hariharan Subramonyam. 2026. SimStep: Human-in-the-Loop Authoring of Interactive Educational Simulations Through Task-Level Abstractions. In *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 75, 34 pages. <https://doi.org/10.1145/3772318.3791514>
- [6] Gyubok Lee, Sunjun Kweon, Seongsu Bae, and Edward Choi. 2024. Overview of the EHRSQL 2024 Shared Task on Reliable Text-to-SQL Modeling on Electronic Health Records. In *Proceedings of the 6th Clinical Natural Language Processing Workshop*. Association for Computational Linguistics, Stroudsburg, PA, USA, 644–654. <https://doi.org/10.18653/v1/2024.clinicalnlp-1.62>
- [7] Damien Masson, Sylvain Malacria, G ry Casiez, and Daniel Vogel. 2024. DirectGPT: A Direct Manipulation Interface to Interact with Large Language Models. In *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 975, 16 pages. <https://doi.org/10.1145/3613904.3642462>
- [8] Seokhyeon Park, Soohyun Lee, Eugene Choi, Hyunwoo Kim, Minkyu Kweon, Yumin Song, and Jinwook Seo. 2026. Bridging Gulfs in UI Generation through Semantic Guidance. In *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 880, 16 pages. <https://doi.org/10.1145/3772318.3791966>
- [9] Venkatesh Sivaraman, Leigh A. Bukowski, Joel Levin, Jeremy M. Kahn, and Adam Perer. 2023. Ignore, Trust, or Negotiate: Understanding Clinician Acceptance of AI-Based Treatment Recommendations in Health Care. In *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 754, 18 pages. <https://doi.org/10.1145/3544548.3581075>
- [10] Priyan Vaithilingam, Elena L. Glassman, Jeevana Priya Inala, and Chenglong Wang. 2024. DynaVis: Dynamically Synthesized UI Widgets for Visualization Editing. In *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*. Association for Computing Machinery, New York, NY, USA, Article 217, 17 pages. <https://doi.org/10.1145/3613904.3642639>