

生成臨床 UI の層間整合性を評価する TraceBench-EHR

TraceBench-EHR: Evaluating Cross-Layer Integrity in Generated Clinical Interfaces

平田 蓮

Ren Hirata

要旨 生成 AI による臨床 UI の増分更新では、SQL と画面が個別に動作しても、情報要求、SQL、実行結果、表示の対応が壊れ得る。本研究は、EHRSQL-2024 と MIMIC-IV Demo から 8 種類の層間不整合を生成し、4 種類の検査条件を同じ候補で比較する TraceBench-EHR を構築する。validation では 931 件中 924 件から基準を生成し、758 組、6,064 候補を得た。8 種類の変異は各 34~133 テンプレートで停止条件を満たし、独立した正解判定との不一致は 0 件だった。test は未実行であり、現時点の結果は評価手順の成立だけを示す。

1. はじめに

電子カルテには、患者属性、入退院、検査、処方、処置など、診療で参照される情報が複数の表と画面に分かれて蓄積される。医療従事者が必要とする情報は診療場面と確認目的によって変わるため、同じ患者データであっても、表示すべき項目、期間、集約方法、提示形式は一意ではない。タスクに応じて画面を生成・更新する臨床ユーザーインターフェース (UI) は、この情報探索を支える一つの方法である。

この更新では、個々の成果物が正常でも、成果物間の対応が壊れる場合がある。たとえば「対象患者の直近 24 時間の腎機能を数値で表示する」という要求に対し、SQL だけが別患者を参照する、24 時間の条件だけが外れる、SQL を更新した後も古い結果が残る、といった候補である。SQL は読み取り専用で実行でき、結果と表示部品も描画できるため、各成果物を個別に検査するだけでは拒否できない。それでも、要求した患者、期間、項目と画面に出る値の対応は壊れている。本稿では、この誤りを**層間不整合**と呼ぶ。

近年の生成 UI 研究では、自然言語から UI コードを直接作る方法に加え、タスクや意味を表す中間表現を介して UI を生成・編集する方法が提案されている。Jelly はタスク駆動データモデルを生成・更新し、そのモデルから UI を構成する [1]。Bridging Gulfs は設計意図の意味表現を、人の入力と生成 UI を結ぶ層として利用する [2]。SimStep は複数のグラフを用いて、生成結果の前提を人が段階的に確認・修正できるようにす

る [3]。これらの研究は検査可能な中間表現を提示するが、臨床情報要求からデータ取得、実行結果、表示までの不整合を、同じ候補と正解判定で比較する評価基盤は示していない。

本研究は、生成された臨床 UI の増分更新を対象に TraceBench-EHR を構築する。EHRSQL-2024[4] の質問と正解 SQL を MIMIC-IV Clinical Database Demo v2.2[5] 上で実行し、基準となる表示までを決定的に生成する。その上で 8 種類の不整合を注入し、各成果物だけを見る局所検査、成果物ごとの契約、グラフによる層間契約、グラフと同じ対応を表形式で持つ平坦な対応表を比較する。平坦な対応表を含めることで、契約内容の効果とグラフ形式の効果に分ける。

本稿の貢献は次の三点である。第一に、臨床情報要求から表示までを対象とする層間不整合の分類を定める。第二に、不整合を再現可能に生成し、実行時検査とは別の処理で正解を判定するベンチマーク設計を示す。第三に、契約内容と保存形式を分けて比較し、検出だけでなく問題箇所の特定と一回の自動修復を評価する。臨床上の安全性、使いやすさ、認知負荷、臨床転帰は本評価の主張範囲に含めない。

2. 関連研究

2.1 生成・更新可能な UI

生成 UI では、利用者の要求から画面または実行可能なコードを作るだけでなく、生成後の変更をどう扱うかが課題となる。直接生成されたコードを局所的に変更すると、変更対象以外の状態、データ参照、表示規則が意図せず変わる可能性がある。Jelly は、利用者の情報タスクをデータモデルとして保持し、自然言語と

直接操作をモデルの変更へ変換する [1]。これにより、UI を作り直すたびにタスク構造が失われる問題へ対処する。

意味中間表現を用いる研究では、利用者が生成モデルの解釈を確認しやすくすることが重視される。Bridging Gulfs は、製品、機能、デザインシステム、部品などの意味を階層的に構造化し、入力意図と出力 UI の対応を提示する [2]。SimStep は Concept Graph、Scenario Graph、Learning Goal Graph、UI Graph を設け、人が各段階の仮定を修正する [3]。本研究も中間表現を使うが、グラフを紹介すること自体を利点とみなさず、情報要求、データ取得、実行結果、表示の契約内容を評価対象にする。

2.2 EHR の Text-to-SQL

EHRSQL は、医療従事者から収集した情報要求を基に、電子カルテを対象とする自然言語質問と SQL の組を提供する。EHRSQL-2024 は MIMIC-IV Demo のスキーマに対応し、回答可能な質問と回答不能な質問を含む共有タスクとして整備された [4]。Text-to-SQL の評価では、質問に対して SQL を正しく生成できるか、回答不能な質問で棄権できるかが中心となる。

TraceBench-EHR は SQL 生成モデルの性能を比較しない。正解 SQL を基準として使用し、その実行結果を表示部品まで接続した後の増分更新を扱う。つまり、質問と SQL の一致に加えて、SQL と実行結果、実行結果と表示方式、更新後の各成果物の同期を検査する。EHRSQL を基盤にする理由は、質問テンプレート、SQL、開発用の train、調整確認用の validation、最終評価用の test という公式分割があり、更新候補と評価規則を test 結果を見る前に固定できるためである。

2.3 モデル変換と整合性検査

構造化データとビューの更新を対応付ける問題は、双方向変換でも扱われてきた。Lens の研究は、元データとビューの間の往復変換が満たすべき性質を定式化している [6]。また、完全な正解出力を列挙しにくいモデル変換に対して、不変関係を用いるメタモルフィックテストが提案されている [7]。本研究では完成した JSON の完全一致を求めず、変更すべき内容と保持すべき内容を述語として表す。

一般的なスキーマ検査や描画検査は必要であるが、これらは一つの成果物の妥当性を確認する。層間不整合の検出には、複数の成果物間で同じ患者、項目、期




図 1 TraceBench-EHR が検査する情報の流れ

表 1 研究質問と評価の対応

質問	比較対象	判断に使う結果
RQ1	8 種類の変異	局所検査の流出数と失敗例
RQ2	4 種類の検査条件	流出率、受理率、特定率
RQ3	一回の修復	成功率、誤修復率、拒否率

間、集約、接続が維持されたかを確認する必要がある。そこで本研究は、局所検査から層間契約までを同じ候補に適用し、検査範囲の違いを明示する。

3. 研究質問と評価の対応

本研究では、増分更新において最終画面や個別成果物の検査を通過する不整合を対象とする。研究質問を次のように定める。

- RQ1：生成された臨床 UI の増分更新では、局所検査を通過する層間不整合がどの種類で生じるか。
- RQ2：局所検査、成果物ごとの契約、層間契約は、不正更新の検出、妥当更新の受理、問題箇所の特定でどのように異なるか。
- RQ3：検証結果を用いた一回の自動修復は、どの不整合を回復でき、どの不整合で失敗または過剰拒否するか。

各研究質問を表 1 の対象と指標へ対応させる。RQ1 は 8 種類の変異ごとに、局所検査を通過した候補数と具体例を調べる。RQ2 は 4 条件の不整合の流出率、妥当な更新の受理率、問題箇所の特定率を比較する。RQ3 は検証結果を使った一回の修復について、成功、誤修復、拒否を分ける。

事前の予想は、局所検査では対象患者や期間などの不整合が通過し、層間契約は不整合の流出を減らしつつ妥当な更新を受理するというものである。ただし、グラフ契約と平坦な対応表には同じ契約内容を持たせる。両者が同じ判定を返す場合、検出性能はグラフ形式ではなく契約内容によるものと解釈する。

表 2 TraceBench-EHR の不整合分類

種類	壊す対応
対象患者	要求と SQL が参照する患者
対象項目	要求項目と取得列・集約対象
期間	時点・期間条件と SQL の絞り込み
情報源	必要情報と参照表
集約方法	件数、最大、最小、平均など
表示方式	結果形状と表示部品の種類
接続	データ取得と表示部品の参照
部分更新	SQL 更新後に残る古い結果

4. TraceBench-EHR の設計

4.1 基準ケースの構築

入力は EHRSQL-2024 の回答可能な質問と正解 SQL である。回答不能ケースは、正解 SQL から基準 UI を構成できないため主評価から除外し、除外数を報告する。正解 SQL は読み取り専用の SQLite 接続で MIMIC-IV Demo v2.2 へ実行する。SQL ごとの実行上限は 5 秒とし、書き込みを含む文、複数文、許可しない構文は実行前に拒否する。

実行結果が単一値の場合は数値カード、複数行や複数列の場合は表を割り当てる。基準ケースは、質問テンプレート、SQL、結果形状、データ取得、表示部品の対応を持つ。患者単位の値を契約へ埋め込まず、ケース ID、入力チェックサム、結果形状、対応識別子を保存する。空結果は除外せず、列構造を持つ表として扱う。

同一の質問テンプレート内にあるケースを更新前後として組み合わせる。これにより、患者、項目、期間などの一部を変えた妥当な更新を作り、同じ基準から不整合候補を生成できる。複数の変異を独立標本として数えず、質問テンプレートを分析上のクラスタとする。

4.2 8 種類の不整合

変異規則は表 2 の 8 種類である。各規則は一つの契約要素を壊し、それ以外の構造を保つ。複数の規則が同じ候補へ偶然混入しないよう、生成後に独立した正解判定で検査する。

対象患者の変異では、要求側の患者を保ったまま SQL の患者条件を別の候補へ変える。対象項目では、要求と異なる列または集約対象を取得する。期間では時間表現に対応する WHERE 条件や並び順を壊す。情報源では同じような列名を持つ別表を参照させる。集

表 3 候補更新と期待する診断の例

候補	局所状態	層間診断
患者誤り	SQL 実行可能	対象患者
期間欠落	SQL 実行可能	期間
結果残留	表示可能	更新世代
参照誤り	描画可能	接続
表示変更	描画可能	表示方式

約方法では、要求された最大値を件数へ変えるなど、SQL として実行可能なまま意味を変える。

表示方式の変異は、SQL、実行結果、列、値を保ち、数値カードを表へ、データフレーム型の表を別の表部品へ変える。局所的には描画可能でも、基準契約が定めた結果形状と表示方式の対応が壊れる。接続の変異は表示部品が別のデータ取得を参照する。部分更新は SQL だけを新しい要求へ変更し、以前の実行結果を保持する。この変異により、各成果物が個別に妥当でも、更新の同期が失敗する状況を作る。

4.3 独立した正解判定

候補生成と正解判定は別の処理にする。正解判定は、質問テンプレートから得た患者、項目、期間、情報源、集約と、SQL の解析結果、実行結果の形状、データ取得と表示部品の参照を照合する。比較対象である実行時検査の判定を正解ラベルとして使うと、同じ誤りを共有して評価値が高く見える可能性があるためである。候補の期待ラベルと独立した正解判定が一致しない場合は、正式評価を停止する。

完全な UI JSON の一致を正解としない理由は、意味を保った複数の表現を許容するためである。基準と異なる安定 ID、表示文言、順序であっても、要求、データ、表示の意味条件を満たす候補は妥当とする。一方、見た目が同じでも別患者や古い結果を表示する候補は不整合とする。

4.4 候補と診断の例

基準ケースが「患者 A の直近 24 時間の検査 X を数値で表示する」である場合を考える。妥当な更新として患者 B へ対象を変更するなら、質問側の患者、SQL の患者条件、実行結果の世代、データ取得と表示部品の参照を同じ更新として変更する必要がある。一つだけ古い状態に残れば、各成果物を単独では処理できても、更新全体として不整合になる。

対象患者の候補では、SQL 文自体が読み取り専用で、存在する患者を参照していれば局所検査を通過し得る。層間契約は、質問と SQL が指す患者の対応を検査し、対象患者の違反として特定する。期間の候補も同様に、時間条件を削除しても SQL 構文と実行可能性は保たれるため、要求の時間表現との照合が必要になる。

部分更新の候補では、更新後の SQL と更新前の実行結果がそれぞれ妥当な形式を持つ。そこで、SQL のチェックサムと実行結果へ付与した更新世代を対応させ、古い結果が残ったことを診断する。接続の候補では、参照先のデータ取得が存在する限り表示できる場合があるため、情報要求から期待するデータ取得と表示部品の接続を検査する。

これらの例では、問題箇所を単に「検証失敗」と返さず、対象患者、期間、更新世代、接続、表示方式のいずれが壊れたかを記録する。この診断単位を修復操作と対応させることで、検出できた候補のうち、期待値が一意に決まる不整合だけを一回の自動修復へ送る。

5. 検査システム

提案システムは、診療場面、情報要求、データ取得、表示部品をノードとする依存グラフを持つ。情報要求には確認または判断準備の内容を、データ取得には参照する EHR 情報と SQL を、表示部品には提示形式と配置を記録する。基準ケースでは、EHRSQL の一つの質問を一つの情報要求に対応させ、正解 SQL によるデータ取得と結果形状に対応する表示部品を接続する。

候補更新を受け取ると、検査器はスキーマ、読み取り専用 SQL、SQL 実行、結果形状、描画可能性を確認する。層間契約を持つ条件では、さらに患者、項目、期間、情報源、集約、表示方式、接続、更新世代を照合する。違反がある場合は、候補を画面へ反映せず、層と契約項目を含む診断を返す。

自動修復は、この診断を一回だけ利用する。患者条件、期間条件、表示部品の参照など、期待値が契約から一意に決まる場合は該当成果物を書き換える。意味が一意でない場合や、複数層にまたがる変更で安全な修復を決められない場合は拒否する。反復的に試行して正解へ近づける方法は採らず、一回の契約ベース修復として成功、失敗、誤修復を区別する。




図2 候補検証と一回の契約ベース修復

6. 実装と再現性

TraceBench-EHR の評価処理は、基準ケースの構築、候補生成、条件別検証、独立した正解判定、統計集計に分ける。基準ケースの構築では、EHRSQL の質問と正解 SQL を読み込み、読み取り専用接続で SQL を実行する。候補生成では、同じ質問テンプレートに属するケースを組み合わせ、固定した変異規則を一つずつ適用する。ここまでの処理は乱数に依存せず、同じ入力と設定から同じ候補チェックサムを得る。

条件別検証は、生成された同一候補を 4 条件へ適用する。各条件は候補を変更せず、利用する検査範囲だけを変える。検証結果は、受理・拒否、違反を特定した層、契約項目、修復操作、検証時間を記録する。独立した正解判定は候補生成と検査の途中結果を参照せず、保存された候補と基準契約から期待ラベルを再計算する。これにより、候補を作った規則の誤りが、そのまま正解判定へ流れ込むことを避ける。

正式評価は CPU だけで実行し、Gemini を含む外部モデルを呼ばない。seed は 20260827、SQL ごとの上限は 5 秒、ブートストラップは 10,000 回とする。実行時刻は計測値として保存するが、候補の同一性を表すチェックサムには含めない。入力データ、設定、コード、候補、集計のチェックサムを実行マニフェストへ記録し、別の出力先へ再実行した場合に候補と集計が一致するかを確認する。

保存する成果物を表 4 に示す。候補の再生成情報には候補を識別する最小情報を置き、条件別の判定には受理・拒否と診断を一実行一行で記録する。集計結果は質問テンプレート単位で作る。実行記録はデータ

表 4 正式評価で保存する成果物

成果物	保存内容
候補の再生成情報	ケース ID、変異種類、チェックサム
条件別の判定	受理・拒否、問題箇所、修復結果
集計結果	変異別件数、指標、95% 信頼区間
実行記録	入力、設定、コード、出力の版

セット、コード、設定、実行環境、出力の版を結び付ける。内部のファイル名や関数名は再現条件ではないため、ここでは扱う情報と役割を示す。

テストでは、8 種類の変異が意図した一つの契約だけを壊すこと、妥当候補が独立した正解判定を満たすこと、グラフ契約と平坦な対応表が同じ判定を返すこと、修復後に再検証が行われることを確認する。さらに、質問文、SQL、患者 ID、結果値を成果物へ書き出そうとした場合に停止する検査を設ける。機能テスト、lint、型チェックがすべて成功しない限り評価版を固定しない。

再現性の対象は、許可された入力から候補、判定、集計を再生成できることまでである。MIMIC 由来の生データや患者単位の結果をリポジトリへ含めないため、第三者が再実行する場合は、各データセットの利用条件に従って入力を取得する必要がある。公開可能な成果物と再配布できない入力を分け、どの版を使ったかをチェックサムで検証できる構成にする。

7. 評価方法

7.1 比較条件

同じ基準ケースと候補を表 5 の 4 条件へ適用する。条件間で候補生成、SQL 実行環境、一般的なスキーマ検査をそろえる。

局所検査は、各成果物が単独で実行可能かを確認する。成果物ごとの契約は、SQL、実行結果、表示部品に期待する属性を個別に持つが、層をまたぐ識別関係を持たない。グラフ契約は、質問、データ取得、SQL、実行結果、表示部品を辺で結ぶ。平坦な対応表は同じ契約内容を表形式で保持する。

グラフ契約と平坦な対応表を比較に含めることで、契約内容の効果と保存形式の効果を分ける。両条件の

表 5 比較する検査条件

条件	検査範囲
局所検査	スキーマ、SQL 安全性、実行、描画
成果物契約 グラフ契約	各成果物が持つ患者・項目など 質問から表示部品までの層間対応
平坦な対応表	グラフと同じ対応を表形式で保持

性能が一致した場合、グラフの一般的な優位性は主張しない。グラフは影響範囲の可視化や編集単位として別の利点を持ち得るが、それは本技術評価だけでは確定しない。

7.2 評価指標

主要評価は**不整合の流出率**と**妥当な更新の受理率**である。不整合の流出率は、不整合候補のうち受理されて UI へ反映可能になった割合であり、低いほどよい。妥当な更新の受理率は、正しい候補のうち SQL 実行と描画まで完了して受理された割合であり、高いほどよい。二つを一つの正解率にまとめないのは、安全な拒否を増やすだけで不整合の流出を下げる条件を区別するためである。

副次評価は、問題箇所の特定率、一回の修復成功率、誤修復率、過剰拒否率、検証時間である。問題箇所は不整合の層と契約項目の組で採点する。修復成功は、修復後の候補が独立した正解判定を満たし、SQL 実行と描画まで完了することと定義する。拒否すべきケースを無理に修復した場合は誤修復として分ける。

条件差と 95% 信頼区間は、質問テンプレートを単位に復元抽出するクラスターブートストラップ 10,000 回で求める。同じ質問から作った複数の変異を独立標本として扱わない。平均だけでなく、変異種類別の分布と代表的な失敗例を報告する。

7.3 分割と停止条件

EHRSQL-2024 の train で実装とテストを作り、validation の回答可能 931 件でパイロットを行う。パイロット通過後に変異規則、独立した正解判定、比較条件、分析コードを commit で固定する。その後、test の回答可能 934 件を一度だけ実行する。test 開始後に評価規則の変更が必要になった場合は実行を停止し、その結果

表 6 EHRSQL 50 件の実行可能性確認

確認項目	結果
正解 SQL の実行成功	50/50
非空結果	49/50
依存グラフの検証成功	50/50
数値カードへの割当	40/50
表への割当	10/50
タイムアウト・書込拒否・SQL エラー	0

を正式評価として使用しない。

ほかの停止条件は、入力チェックサムの不一致、テスト・lint・型チェックの失敗、基準 SQL 実行またはグラフ検証成功率が 95% 未満、各変異が 10 テンプレートまたは 30 候補未満、保存成果物への質問文・SQL・患者 ID・結果値の混入である。停止条件を先に定めることで、評価結果を見た後の規則変更を抑える。

8. 確認済みの結果

8.1 50 件の実行可能性確認

2026 年 8 月 27 日に、train 分割の回答可能ケースから異なる質問テンプレートを優先して 50 件を選び、正解 SQL の実行と最小の依存グラフへの変換を確認した。結果を表 6 に示す。

全 50 件で正解 SQL を実行でき、依存グラフの検証に成功した。49 件で非空結果を取得し、1 件は列を持つ空結果だった。結果形状に基づき 40 件を数値カード、10 件を表へ割り当てた。タイムアウト、SQL エラー、書き込み拒否、グラフ検証エラーはなかった。この結果は、選定した 50 テンプレートを現行実装へ機械的に変換できることを示す。全ケースへの適用可能性や表示方式の臨床的妥当性を示すものではない。

初回の成果物では、SQLite が返す列名に SQL 断片が含まれるケースがあった。この出力を無効とし、列名を成果物へ保存しないよう修正して再実行した。最終成果物には質問文、SQL、患者 ID、患者単位の結果値が含まれないことを確認した。この事例から、評価指標だけでなく、生成物への機微情報の混入を停止条件として機械的に検査する必要がある分かった。

8.2 UI 更新技術評価 v0.4

TraceBench-EHR に先立つ予備評価として、合成した 24 ケースと 120 件の共通変更仕様を用い、同じ更新要

求と安全要件を持つ直接差分方式と完全グラフ方式を比較した。各ケースは妥当候補 1 件、単一違反 3 件、複合違反 1 件を持つ。比較中に生成モデルを呼ばず、候補は決定的に作成した。

直接差分方式と完全グラフ方式は、ともに違反候補 96 件をすべて拒否し、妥当候補 24 件をすべて受理した。違反流出率と妥当更新受理率の対応差は 0.0 で、95% 区間も 0.0 から 0.0 だった。グラフ方式から変更対象外の保護、安全条件、追跡検査を個別に外した条件では、対応する違反 18 件が通過した。

この結果は、同じ契約内容を実装した範囲で、グラフ形式そのものが直接差分より高い検出性能を持つという仮説を支持しなかった。一方、各制御を外したときに対応する違反が通過したため、更新範囲、安全条件、追跡関係を明示的に検査する役割は確認できた。そこで正式評価では、グラフ方式に弱い基準だけを置かず、同じ契約内容を持つ平坦な対応表を比較条件にする。

8.3 validation パイロット

正式評価 v1.0 の初回パイロットでは、validation 全 1,163 件のうち正解 SQL を持つ 931 件を対象とした。SQL 実行は 924 件で成功し、成功率は 99.25% だった。625 組、5,000 候補を評価したが、当初予定した列対応の変異は候補 0 件、テンプレート 0 件となった。validation で実行に成功した SQL 結果がすべて 1 列であり、列順を変えて意味的な対応を壊す候補を構成できなかったためである。

この結果は事前の最小件数を満たさないため、v1.0 を固定せず、列対応を表示方式の対応へ置き換えた v1.1 へ更新した。他の 7 種類の変異、4 比較条件、主要・副次評価、分析方法、seed、データ管理、停止条件は維持した。

v1.1 の再実行では、924 件の基準ケースから 758 組、6,064 候補を生成した。表 7 に示すとおり、8 種類の変異はそれぞれ 34~133 テンプレートを含み、各変異 10 テンプレート以上、30 候補以上という停止条件を満たした。独立した正解判定と期待ラベルの不一致は 0 件、グラフ契約と平坦な対応表の判定不一致も 0 件だった。保存成果物に質問文、SQL、患者 ID、患者単位の結果値が含まれないことを確認した。

この結果から判断できるのは、候補生成、正解判定、比較条件の対応、データ非保存条件が test 実行前の基準を満たしたことだけである。test split はまだ実行し

表 7 TraceBench-EHR v1.1 の validation 結果

確認項目	結果
回答可能ケース	931
基準生成成功	924 (99.25%)
更新前後の組	758
4 条件へ入力した候補	6,064
変異ごとのテンプレート	34~133
正解判定との不一致	0
グラフと対応表の不一致	0
機微情報を含む保存成果物	0

ていないため、4 条件の不整合の流出率、妥当な更新の受理率、問題箇所の特定期率、修復成功率は未確定である。

9. 考察

9.1 RQ1：局所検査を通過し得る不整合

50 件の実行可能性確認では、正解 SQL を依存グラフと表示部品へ変換できた。一方、これは各層を正しく接続した基準ケースの確認であり、増分更新後に対応が保たれることを保証しない。SQL が実行できること、結果が表であること、表示部品が描画できることは、すべて必要条件である。しかし、患者、項目、期間、集約、表示の意味が一致しているかは別の検査を要する。

層間不整合は、最終画面の見た目から判別しにくい。別患者の値でも数値カードとして表示でき、古い結果でも描画エラーは起きない。したがって、画面の画像比較や UI コードの構文検査だけでは、情報要求に対する正しさを判定できない。8 種類のうち、どれが局所検査を何件通過するかは test 結果で確定する。

9.2 RQ2：契約内容とグラフ形式

予備評価 v0.4 で直接差分方式と完全グラフ方式に差がなかったことは、グラフを用いれば自動的に整合性が得られるという説明を支持しない。同じ契約を成果物側に実装できるなら、検出性能は同じになる可能性がある。そこで TraceBench-EHR は、グラフと同じ情報を持つ平坦な対応表を比較する。

v1.1 の validation では、グラフ契約と平坦な対応表の判定不一致が 0 件であることを確認した。これは比較条件へ同じ契約内容を実装できたことの確認であり、性能差がないという結果ではない。不整合の流出率や受理率の差は test で判断する。本稿では、保存形式と

しての JSON、関係表、グラフデータベースの一般的な優劣を主張しない。

9.3 RQ3：一回の自動修復の範囲

契約から期待値が一意に決まる不整合は、自動修復の対象にできる。たとえば表示部品が参照すべきデータ取得、SQL 更新後に対応する結果世代、基準ケースで定めた表示方式は、診断から修復操作を構成できる。一方、自然言語要求が複数の解釈を許す場合や、表示粒度と臨床的な意味の選択が必要な場合、技術的な契約だけで正解を決められない。

そのため、修復率を高くすることだけを目的にしない。誤修復と過剰拒否を分け、安全に一意化できない場合は拒否する。修復成功率、誤修復率、拒否率は test を実行して初めて確定する。将来、人による評価を行う場合は、成果物の差分だけを提示する条件と、影響範囲、根拠、保護条件を提示する条件を比較し、専門家が誤りを検出・修正できるかを調べる。

9.4 評価設計から得た知見

validation 初回パイロットで列対応の変異を作れなかったことから、故障モデルを概念だけで固定せず、実データの結果形状で生成件数を確認する必要があることが分かった。列対応を表示方式へ変更した v1.1 は、8 種類すべてで事前の最小件数を満たした。変更理由、維持した条件、再実行結果を版ごとに残すことで、test 結果を見た後の規則変更と区別できる。

また、質問テンプレート単位で集計する必要がある。同じテンプレートから患者や項目だけを変えたケースは、SQL 構造と不整合生成規則を共有する。候補単位で独立に数えると、特定のテンプレートが結果へ過大に寄与する。クラスターブートストラップと変異種類の報告により、評価単位の依存を明示する。

10. 制約と倫理

本研究は MIMIC-IV Clinical Database Demo v2.2 を用いる技術評価である。評価から、臨床上の安全性、診療判断の正確さ、使いやすさ、認知負荷、臨床転帰、実運用、他施設への一般化を主張しない。正解 SQL は技術的な基準であり、表示内容の医学的な妥当性を専門家が確認した基準ではない。

人を対象とする評価は初回の主評価から外している。既存の専門家評価案は、倫理審査と実施許可の範囲、募集方法、データ保存、同意、撤回方法が確認されるま

表 8 今後の作業

時期	作業
9月5日まで	評価版のレビューと commit による固定
9月6日	test 934 件の一回実行と別経路集計
9月6～8日	指標、95% 区間、失敗例、修復例の確定
9月9日 修士論文	原稿、匿名化、再現資料の最終確認 技術評価と将来の人対象評価を分けて統合

で実施しない。KLM による予備的な操作数の確認も、読解、見落とし、判断、認知負荷を示す結果として扱わない。

生データ、質問文、正解 SQL、患者 ID、患者単位の結果値は GitHub と Notion へ保存しない。Git 管理外の一時領域だけで扱い、公開成果物にはケース ID、入力と候補のチェックサム、変異種類、判定結果、集計、実行マニフェストを保存する。MIMIC 由来の派生成果物に関する利用条件を確認し、データセットのライセンスと出典を明記する。

11. 次の作業と完了条件

修士論文までの作業を表 8 に示す。v1.1 の validation 再実行は 2026 年 8 月 27 日に完了した。次は評価規則、設定、分析コード、入力チェックサム、データ非保存条件をレビューし、9 月 5 日までに評価版を commit で固定する。完了条件は、テスト、lint、型チェックが成功し、保存成果物に質問文、SQL、患者 ID、患者単位の結果値がなく、独立集計で候補数と停止条件を再現できることである。

固定後、test の回答可能 934 件を一度だけ実行する。入力チェックサムの不一致、テストの失敗、基準生成成功率 95% 未満、変異の最小件数不足、機微情報の保存を検出した場合は停止し、その実行を正式結果に使わない。通過した場合は、変異種類ごとの流出率、受理率、特定率、修復率と 95% 信頼区間を 9 月 8 日までに確定する。評価規則の変更が必要な場合は版を上げ、test 結果を見た後の変更として記録する。

修士論文では、プロトタイプのシステム設計、UI 更新予備評価、TraceBench-EHR の設計と正式評価を一つの流れとして整理する。人対象評価は、技術評価で

検出・特定・修復の範囲を確立した後の課題として分ける。臨床 UI の利用効果を扱う場合は、専門家確認済みの症例と採点基準を用い、タスク成功率、成功試行の完了時間、操作数、NASA-TLX、SUS を別々に報告する。

12. まとめ

本研究は、生成臨床 UI の増分更新で、臨床情報要求、SQL、実行結果、表示部品の対応が壊れる層間不整合を扱う。TraceBench-EHR は EHRSQL-2024 と MIMIC-IV Demo を基に基準 UI を構成し、8 種類の不整合を決定的に注入する。局所検査、成果物ごとの契約、グラフ契約、同じ内容を持つ平坦な対応表を同じ候補で比較し、検出、妥当更新の受理、問題箇所の特定、一回の修復を評価する。

現在までに、異なる 50 テンプレートで正解 SQL の実行と依存グラフへの変換を確認した。予備評価では、同じ契約内容を持つ直接差分方式とグラフ方式の検出性能に差がなかった。v1.1 の validation では 924 件の基準ケースから 758 組、6,064 候補を生成し、8 種類の変異が事前の停止条件を満たした。独立した正解判定との不一致は 0 件だった。test は未実行であるため、現時点では評価手順の成立だけを確認済みとする。評価版を固定した後に test を一度だけ実行し、3 つの研究質問へ回答する。

参考文献

- [1] Yining Cao, Peiling Jiang, and Haijun Xia. Generative and malleable user interfaces with generative and evolving task-driven data model. In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, pp. 1–20, 2025.
- [2] Seokhyeon Park, Soohyun Lee, Eugene Choi, Hyunwoo Kim, Minkyu Kweon, Yumin Song, and Jinwook Seo. Bridging gulfs in UI generation through semantic guidance. In *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*, pp. 1–16, 2026.
- [3] Zoe Kaputa, Anika Rajaram, Vryan Feliciano, Zhuoyue Lyu, Maneesh Agrawala, and Hariharan Subramonyam. SimStep: Human-in-the-loop authoring of interactive educational simulations through task-level abstractions. In *Proceedings of the 2026*

CHI Conference on Human Factors in Computing Systems, pp. 1–34, 2026.

- [4] Gyubok Lee, Sunjun Kweon, Seongsu Bae, and Edward Choi. Overview of the EHRSQL 2024 shared task on reliable text-to-SQL modeling on electronic health records. In *Proceedings of the 6th Clinical Natural Language Processing Workshop*, pp. 644–654. Association for Computational Linguistics, 2024.
- [5] Alistair Johnson, Lucas Bulgarelli, Tom Pollard, Steven Horng, Leo Anthony Celi, and Roger Mark. MIMIC-IV. *PhysioNet*, 2023. Version 2.2.
- [6] J. Nathan Foster, Michael B. Greenwald, Jonathan T. Moore, Benjamin C. Pierce, and Alan Schmitt. Combinators for bidirectional tree transformations: A linguistic approach to the view-update problem. *ACM Transactions on Programming Languages and Systems*, Vol. 29, No. 3, 2007.
- [7] Xiao He, Zhenjiang Li, Zhenjiang Hu, Xiaoyu Liu, and Takashi Hirayama. Testing bidirectional model transformation using metamorphic testing. *Information and Software Technology*, Vol. 104, pp. 48–69, 2018.