

CHI採択研究を参考にした 更新の監査・修復評価

評価方法の候補と推奨案・2026-08-14

京都大学大学院 情報学研究科・平田 蓮

構造と修復の評価方法を参考にする

論文	採用している評価	今回への使い方
SimStep	層をまたぐ完全性、一貫性、意味変化、動作、修復率と操作	不整合の発見率、修復成功率、修復操作数を測る
Jelly	25課題50要求を2人が評価し、不一致を第三者が裁定	必要性、欠落、誤接続、冗長性を専門家が監査する
DirectGPT	局所・全体変更の成功、時間、操作、回復、結果の明瞭さ	局所更新と層をまたぐ更新を分け、特定と修復を測る

人の判断と条件統制の方法を参考にする

論文	採用している評価	今回への使い方
Ignore, Trust, or Negotiate	医療者24人の判断、確信度、説明利用、think-aloud	受理、拒否、部分修正の判断過程を調べる
Bridging Gulfs	同じ生成モデルを用いた被験者内比較	追跡情報の提示だけを条件間で変える
MIND	臨床家16人、同じデータ、模擬症例、順序の入れ替え	候補と最終UIを揃え、提示方法だけを操作する

更新の監査・修復評価を推す

1・SimStepから借りる

層をまたぐ不整合の特定、修復成功、修復操作を評価する。

2・Ignore, Trust, or Negotiateから借りる

受理、拒否、部分修正、確信度、判断理由を評価する。

3・組み合わせる

追跡情報が人の監査と修復を支援するかを被験者内で比べる。

追跡情報の提示だけを変える

基準条件

最終UIと成果物差分を提示する。
一般検査の結果も確認できる。

追跡条件

基準条件に加えて、影響範囲、根拠、保護条件、タスクからWidgetまでの追跡経路を提示する。

両条件で更新候補、症例、修復画面、制限時間を揃える

参加者は同じ手順で監査する

① 更新を受理するか拒否するか判断する



② 問題のある要素や依存関係を特定する



③ 同じ修復画面を使って修正する



④ 判断の確信度を回答する



⑤ 判断理由を発話または事後面接で説明する

正確性を主要評価にする

主要評価

不適切な更新の誤受理率

妥当な更新の正受理率

問題箇所の特定期間と修復成功率

副次評価

判断時間、操作数、確信度

追跡情報の参照箇所

発話または面接で得た判断理由

時間だけを主要評価にはしない

最終画面だけでは気づきにくいケースを含める

① 表示値は正しいが、取得期間が誤っている

② 必要情報とSQLの接続が切れている

③ 別タスクの安全条件を壊している

④ 問題のない妥当な更新も混ぜる

評価対象を人の監査と修復へ移す

二方式を直接比べる場合

同じ検査を実装すると結果が同点になりやすい。

グラフ形式の性能だけを測る比較になる。

追跡情報の提示を比べる場合

候補と最終UIを同じにできる。

人の問題発見、判断、修復への支援を測れる。

現在の案と未確定事項

現在段階

技術評価の結果を受けた評価設計の見直し

成果案

更新の監査・修復を中心にした被験者内比較

確認済み

CHI採択論文6件の評価方法と今回への適用候補

未確定

臨床ケースの正解、参加者、倫理上の実施可否

次に行うこと

ケース構成、画面条件、評価指標を具体化する