

監査可能な臨床UI更新を どう評価するか

研究質問と評価設計の整理・2026-08-14

京都大学大学院 情報学研究科・平田 蓮

今回の要点

問題

生成したUIを更新すると、臨床上必要な依存関係を壊すおそれがある

方針

追跡関係と保護条件を使い、更新前に影響と違反を検査する

評価

更新制御をRQ1、人による更新判断をRQ2として分けて検証する

相談

比較の公平性と、人を対象とする評価の実施可能性を確認したい

研究質問の出発点は三つのずれだった

概念

ヒアリングの診療タスクT1～T7と、実装の3つの画面タブが混同されていた

評価

KLMは操作経路を扱うが、情報の見落としや判断の正しさは測れない

貢献

既存EHRとの利用比較だけでは、タスクグラフを使う効果を分離できない

問いは三段階で絞った

① 診療タスクと画面構成を分離する

7月16日



② 利用効果と更新機構の評価を分離する

7月24日



③ 更新制御をRQ1、人の判断支援をRQ2に分離する

8月14日

反論を研究設計へ変えた

論点	問題	研究設計への反映
正確性	速い誤答も良い結果になる	正確性を先に評価し、時間を副次評価にする
基準条件	グラフ条件内では中間表現の効果を分けられない	同じ安全要件を持つ直接差分方式と比べる
交絡	条件ごとに Gemini を動かすと生成性能が混ざる	更新候補を凍結し、更新制御と分ける
人への利益	違反検出だけでは専門家への利益を説明できない	判断と修復への支援を RQ2 で評価する

RQ1とRQ2は同じ構成要素で組み立てた

要素	RQ1	RQ2
対象	凍結した臨床UIの更新候補	凍結した更新候補を確認する専門家
提案	追跡可能なグラフを介する更新制御	影響範囲、根拠、保護条件の表示
比較	同じ安全要件を持つ成果物直接差分	最終UIと成果物差分だけの表示
主要評価	違反流出率と正常受理率	不適切な更新の誤受理と判断正答率
境界	Gemini と使いやすさを主比較から外す	倫理確認前は実施せず、臨床転帰を扱わない

主比較から外した案にも役割を残した

外した案	主比較に置かない理由	現在の扱い
既存EHRと提案UI	UIの利用効果であり、更新機構の寄与ではない	将来の利用評価
グラフ方式の検査を一つずつ外す	中間表現の有無を比較できない	機構の要因分析
Geminiを含む一連の更新	候補生成と更新制御が交絡する	補助評価とシステム全体の評価
グラフ全体やUI全体の再生成	現在想定する増分更新と条件が異なる	主比較の対象外


グラフを挟むだけでは新規性にならない

研究	すでに示したこと	本研究で残る問い
Jelly	タスク駆動モデルによるUI生成と継続的な変更	臨床上の保護条件と層間の追跡を守れるか
SimStep	複数グラフを人が確認・修正するチェックポイント	臨床UI更新を受理・拒否・修復できるか
Bridging Gulfs	意味表現がUI生成の理解と制御を支援	影響範囲と根拠の提示が更新判断を助けるか

評価するのは層をまたぐ追跡と保護

更新要求

腎機能の推移を確認できるよう、表を時系列グラフへ変更する



保護条件

最新値を残す・対象外のタスクを変えない・SQLを実行できる・追跡を切らない

変更対象だけを更新し、臨床タスクから表示までの関係を保つ

二つの研究質問を別の比較で検証する

RQ1 更新制御

同じ更新要求と安全要件の下で、グラフ経由の更新は直接差分更新より 依存関係の破壊を抑えられるか。

RQ2 人による更新判断

影響範囲、根拠、保護条件の提示は、成果物差分だけの提示より 検出、判断、修復を支援できるか。

RQ1はグラフ方式と直接差分方式を比べる

比較

成果物への直接差分更新と、グラフを介する差分更新

共通条件

初期UI、更新要求、安定ID、安全要件、一般検査


候補

共通変更仕様から意味上対応する二種類の差分を作る

除外

主比較ではGeminiを呼ばず、UI全体も再生成しない

RQ1では受理と拒否を別々に測る



主要評価

- 違反候補がUIへ流出した割合
- 正しい候補を受理できた割合
- 違反の種類ごとの失敗例

検査を一つずつ外す比較は要因分析として扱う

RQ2は更新を確認する人への支援を比べる

基準条件

更新要求、更新後UI、成果物差分、一般検査の結果を示す

提案条件

基準条件に影響範囲、根拠、保護条件、違反箇所を加える


課題

更新の受理・拒否、問題箇所の特定、修復、確信度の回答

対象候補

医療者または臨床情報を判断できる専門家

RQ2は正しい判断と修復を中心に測る



主要評価と停止条件

- 不適切な更新を誤って受理した割合
- 受理・拒否判断の正答率
- 倫理と実施許可が不明なら開始しない

判断時間と確信度は正確性に対応付けて解釈する

二つの評価で一つの主張を支える

RQ1 更新を制御できるか

① 違反をUI反映前に検出する



② 正しい更新を過剰に拒否しない



③ どの検査が効いたかを分ける

RQ2 人が判断できるか

① 不適切な更新を検出して拒否する



② 壊れた関係を特定する



③ 根拠を確認して修復する

機械の検査と人の判断を合わせて監査可能性を評価する

主張する範囲を先に限定する

評価から主張したいこと

合成症例と凍結した更新候補で、依存関係を守りながら更新できるか。

影響表示が専門家の判断を支援するか。

この評価だけでは主張しないこと

グラフという保存形式の一般的な優位性。

臨床転帰、実運用上の安全性、他診療科や現行EHRへの一般化。

CHI 2027へ向けた判断期限

1 研究質問、倫理、参加者候補を確認

8月17日

2 比較条件、安全要件、評価手順を固定

8月20日

3 技術評価版と人対象評価の実施可能性を確認

8月27日

4 方法、結果、図表を原稿へ反映

9月2日

5 CHI 2027 Papersへ提出

9月10日 AoE

ゼミで確認したいこと

三つの判断を相談したい

- **RQ1とRQ2の組合せでCHIの貢献を説明できるか**
- **同じ安全要件を持つ直接差分方式は公平な基準条件か**
- **RQ2の倫理確認、参加者確保、実施を締切前に進められるか**