

CHI採択研究を参考にした 更新の監査・修復評価

9月10日のCHI提出に向けた評価方法の検討・2026-08-14

京都大学大学院 情報学研究科・平田 蓮

今回伝えたいこと

研究質問

更新制御をRQ1、人による更新判断をRQ2として再整理した

技術評価

CHI採択研究を参考に、研究質問に合う評価方法を探る

相談

月末に矢部先生との相談機会をいただいている

目標

相談結果を反映し、9月10日のCHI 2027 Papers提出を目指す

構造と修復の評価方法を参考にする

論文	採用している評価	今回への使い方
SimStep	層をまたぐ完全性、一貫性、意味変化、動作、修復率と操作	不整合の発見率、修復成功率、修復操作数を測る
Jelly	25課題50要求を2人が評価し、不一致を第三者が裁定	必要性、欠落、誤接続、冗長性を専門家が監査する
DirectGPT	局所・全体変更の成功、時間、操作、回復、結果の明瞭さ	局所更新と層をまたぐ更新を分け、特定と修復を測る

人の判断と条件統制の方法を参考にする

論文	採用している評価	今回への使い方
Ignore, Trust, or Negotiate	医療者24人の判断、確信度、説明利用、think-aloud	受理、拒否、部分修正の判断過程を調べる
Bridging Gulfs	同じ生成モデルを用いた被験者内比較	追跡情報の提示だけを条件間で変える
MIND	臨床家16人、同じデータ、模擬症例、順序の入れ替え	候補と最終UIを揃え、提示方法だけを操作する

更新の監査・修復評価を推す

1・SimStepから借りる

層をまたぐ不整合の特定、修復成功、修復操作を評価する。

2・Ignore, Trust, or Negotiateから借りる

受理、拒否、部分修正、確信度、判断理由を評価する。

3・組み合わせる

追跡情報が人の監査と修復を支援するかを被験者内で比べる。

追跡情報の提示だけを変える

基準条件

最終UIと成果物差分を提示する。
一般検査の結果も確認できる。

追跡条件

基準条件に加えて、影響範囲、根拠、保護条件、タスクからWidgetまでの追跡経路を提示する。

両条件で更新候補、症例、修復画面、制限時間を揃える

参加者は同じ手順で監査する

① 更新を受理するか拒否するか判断する



② 問題のある要素や依存関係を特定する



③ 同じ修復画面を使って修正する



④ 判断の確信度を回答する



⑤ 判断理由を発話または事後面接で説明する

正確性を主要評価にする

主要評価

不適切な更新の誤受理率

妥当な更新の正受理率

問題箇所の特定期間と修復成功率

副次評価

判断時間、操作数、確信度

追跡情報の参照箇所

発話または面接で得た判断理由

時間だけを主要評価にはしない

最終画面だけでは気づきにくいケースを含める

① 表示値は正しいが、取得期間が誤っている

② 必要情報とSQLの接続が切れている

③ 別タスクの安全条件を壊している

④ 問題のない妥当な更新も混ぜる

評価対象を人の監査と修復へ移す

二方式を直接比べる場合

同じ検査を実装すると結果が同点になりやすい。

グラフ形式の性能だけを測る比較になる。

追跡情報の提示を比べる場合

候補と最終UIを同じにできる。

人の問題発見、判断、修復への支援を測れる。

現在の案と未確定事項

現在段階

技術評価の結果を受けた評価設計の見直し

成果案

更新の監査・修復を中心にした被験者内比較

確認済み

CHI採択論文6件の評価方法と今回への適用候補

未確定

臨床ケースの正解、参加者、倫理上の実施可否

次に行うこと

ケース構成、画面条件、評価指標を具体化する

9月10日の提出へ向けた予定

1 技術評価の方法と実施範囲の候補を整理する

8月下旬

2 矢部先生に評価方法を相談する

8月末

3 相談結果を評価計画と原稿へ反映する

9月上旬

4 CHI 2027 Papersへ提出する

9月10日