

# TraceBench-EHRの技術評価

実験内容と主張できること・2026-08-28

平田 蓮

# 今回わかったこと

個別の確認

不整合763件をすべて通した

対応を照合


不整合763件をすべて止めた

保存形式

グラフと1枚の表で判定差はなかった

この実験で効いたのは、グラフ形式ではなく、質問から表示までの対応を明示したこと

## 各部品が動いても、全体は間違ふことがある



質問と表示内容の対応が壊れていても、**SQL**と画面だけを見ると正常に見える

# 公開データを組み合わせた

**EHRSQL-2024**

**電子カルテへの質問、質問形式、正解SQL**

**MIMIC-IV Demo v2.2**

**正解SQLを実行する匿名化済みの公開デモデータ**

**テスト用データ**

**全1,167件のうち、正解SQLがある934件**

# 正しい組み合わせを1か所だけ壊した

① 質問と正解SQLから基準を作る



② SQLを実行して結果と表示方法を決める



③ 対応を1か所だけ意図的に壊す



④ 4種類の確認方法へ同じ候補を渡す

正しい候補と不整合候補を対にして、見逃しと過剰な拒否を分けて測った

# 8種類の不整合を作った

質問とSQL

患者、対象項目、期間、集約方法

SQLと情報源

参照したデータの説明

結果と表示

表示方式、データと画面の接続

SQLと実行結果

更新後も古い結果を残す

すべて、SQLを実行でき、画面にも表示できる候補として作成

## 4種類の確認方法を比べた

- 1 局所確認：SQLや画面部品が単独で動くか
- 2 成果物ごとの契約：SQL、結果、画面部品が個別に整合するか
- 3 グラフ契約：質問から表示までの対応がつながるか
- 4 サイドカー契約：同じ対応を1枚の表として照合できるか

グラフとサイドカーには同じ確認内容を持たせた

# テスト用データでの評価は一度だけ実行した

評価ケース

934件

質問形式

134種類

候補の組

763組

検証回数

6,104回

934件すべてでSQL実行と基準成果物の作成に成功



# 層をまたぐ確認だけが全件を止めた

| 不整合流出率   |                      | 間違った候補を誤って通した割合 |         |
|----------|----------------------|-----------------|---------|
| 確認方法     | 不整合を通した<br>件数        | 正しい候補を通<br>した件数 |         |
| 局所確認     | 763 / 763<br>100.00% | 763 / 763       | 100.00% |
| 成果物ごとの契約 | 367 / 763<br>48.10%  | 763 / 763       | 100.00% |
| グラフ契約    | 0 / 763 0.00%        | 763 / 763       | 100.00% |
| サイドカー契約  | 0 / 763 0.00%        | 763 / 763       | 100.00% |

➡ 対応関係を確認すると、正しい候補を残したまま不整合を止められた

# 個別の整合性と全体の整合性は別だった

## 成果物ごとの契約

情報源、表示方式、古い結果は検出できた

患者、対象項目、期間、集約方法、誤接続は十分に扱えなかった

## 層をまたぐ契約

8種類すべてを検出した

問題箇所の特定と1回の修復も763件すべてで成功した

# グラフ形式そのものの優位性は出なかった

| 比較      | 不整合流出率の差    | 95%区間              |
|---------|-------------|--------------------|
| 対 局所確認  | -100.00ポイント | [-100.00, -100.00] |
| 対 成果物契約 | -48.10ポイント  | [-49.56, -46.53]   |
| 対 サイドカー | 0ポイント       | [0, 0]             |

グラフとサイドカーの判定不一致は0件

# 主張できることと、まだ主張できないこと

## 主張できること

個別確認だけでは、層をまたぐ不整合を見逃す

明示した対応関係は、不整合の検出、場所の特定、1回の修復に使える

## まだ主張できないこと

グラフ形式が平坦な表より優れている  
実際の生成モデルや医療現場でも同じ性能になる

臨床上の安全性や使いやすさが向上する

# CHIでは契約内容の効果として説明する

## 問題

正常に動く部品の間で意味の対応が壊れる

示せたこと



示していないこと

層をまたぐ契約で不整合を検出

正しい候補は拒否しなかった

問題箇所を特定して1回の修復

グラフ形式だけによる性能向上

複数不整合や生成モデルへの一般化

臨床的な有効性と安全性



TraceBench-EHRは、質問から表示までの対応を再現可能に評価する技術基盤