

TraceBench-EHRの技術評価

実験内容と主張できること・2026-08-28

平田 蓮

今回わかったこと

個別の確認

間違い763件をすべて通した

全体の確認


間違い763件をすべて止めた

まとめ方

グラフと1枚の表で判定差はなかった

この実験で効いたのは、グラフ形式ではなく、質問から表示までの対応を明示したこと

各部品が動いても、全体は間違ふことがある



質問と表示内容がずれていても、**SQL**と画面だけを見ると正常に見える

公開データを組み合わせた

EHRSQL-2024

電子カルテへの質問、質問形式、正解SQL

MIMIC-IV Demo v2.2

正解SQLを実行する匿名化済みの公開デモデータ

テスト用データ

全1,167件のうち、正解SQLがある934件

正しい組み合わせを1か所だけ壊した

① 質問と正解SQLから基準を作る



② SQLを実行して結果と表示方法を決める



③ 対応を1か所だけ意図的に壊す



④ 4種類の確認方法へ同じ組み合わせを渡す

正しい組み合わせと間違った組み合わせを対にして、見逃しと誤った停止を分けて測った

8種類のずれを作った

質問とSQL

患者、対象項目、期間、数え方

SQLと情報源

参照したデータの説明

結果と表示

表示方式、データと画面の接続

SQLと実行結果

更新後も古い結果を残す

すべて、SQLを実行でき、画面にも表示できる組み合わせとして作成

4種類の確認方法を比べた

- 1 単独の動作確認：SQLや画面部品が単独で動くか
- 2 部品ごとの確認：SQL、結果、画面部品が個別に合っているか
- 3 グラフで全体を確認：質問から表示までの対応がつながるか
- 4 1枚の表で全体を確認：同じ対応を表にまとめて確認できるか

グラフと1枚の表には同じ確認項目を持たせた

実際の1件では「今年」の条件だけを外した

データ

MIMIC-IV Demoの集中治療室への入室記録

質問

ある患者について、今年の集中治療室への入室回数を知りたい

正しい処理

集中治療室への入室時刻を今年に限定して回数を数える

間違った処理

期間条件を外し、全期間の回数を数える

確認結果

単独の動作確認と部品ごとの確認では通過。
全体の確認では停止

どちらもSQLは実行でき、回数を1行で表示できる。患者IDと結果値は表示しない

テスト用データでの評価は一度だけ実行した

評価した質問

934件

質問形式

134種類

組み合わせの
対

763組

確認回数

6,104回

934件すべてでSQLを実行し、確認の基準を作れた

質問から表示までの確認だけが全件を止めた

見逃し率

間違った組み合わせを誤って通した割合

確認方法	>	間違いを通した件数	正しい組み合わせを通した件数
単独の動作確認		763 / 763 100.00%	763 / 763 100.00%
部品ごとの確認		367 / 763 48.10%	763 / 763 100.00%
グラフで全体を確認		0 / 763 0.00%	763 / 763 100.00%
1枚の表で全体を確認		0 / 763 0.00%	763 / 763 100.00%



対応関係を確認すると、正しい組み合わせを残したまま間違いを止められた

部品ごとの正しさと、全体の正しさは別だった

部品ごとの確認

情報源、表示方式、古い結果は見つけられた

患者、対象項目、期間、数え方、つながり間違いは十分に扱えなかった

質問から表示までの確認

8種類すべてを見つけた

問題の場所を特定し、1回で直すことも
763件すべてで成功した

グラフ形式だけの良さは確認できなかった

比較	見逃し率の差	95%区間
対 単独の動作確認	-100.00ポイント	[-100.00, -100.00]
対 部品ごとの確認	-48.10ポイント	[-49.56, -46.53]
対 1枚の表	0ポイント	[0, 0]

グラフと1枚の表で判定が異なる例は0件

主張できることと、まだ主張できないこと

主張できること

個別確認だけでは、部品間の意味のずれを見逃す

明示した対応関係は、意味のずれを見つけ、場所を特定し、1回で直すために使える

まだ主張できないこと

グラフ形式が1枚の表より優れている

実際の生成モデルや医療現場でも同じ性能になる

医療現場での安全性や使いやすさが上がる

CHIでは、確認内容の効果として説明する

問題

正常に動く部品の間で意味の対応が壊れる

示せたこと ➤

示していないこと

質問から表示までを確認し、意味のずれを発見

グラフだけで性能が上がる

正しい組み合わせはすべて通した

複数のずれや生成モデルでも同じか

問題の場所を特定し、1回で修正

医療現場で役立ち、安全か



TraceBench-EHRは、質問から表示までの対応を同じ手順で確かめる仕組み